

Trabajo de Fin de Grado en Física

El clima terrestre como sistema complejo de procesos estocásticos

Junio de 2026

Alumno: Guillermo Ramos Flores

Tutor: Juan Carlos Jiménez Muñoz

Resumen

Nuestro conocimiento del clima de la Tierra y cómo la humanidad ha influido sobre él ha experimentado un gran avance en los últimos años. En el año 2021 se otorga el Premio Nobel de Física a los investigadores Syukuro Manabe y Klaus Hasselmann por la modelización física del clima de la Tierra, la cuantización de la variabilidad y la predicción fiable del calentamiento global, y al investigador Giorgio Parisi por el descubrimiento de la interacción del desorden y las fluctuaciones en los sistemas físicos desde la escala atómica a la planetaria. Se trata por tanto del primer premio Nobel en Física relacionado con el estudio del clima de nuestro planeta y por tanto con la climatología. En este trabajo mostraremos algunas de las bases físicas y matemáticas que permiten modelizar el clima de la Tierra entendido como un sistema complejo. Por una parte, nos centraremos en la modelización estocástica de Hasselmann y su aplicación a un caso práctico como es la variación en las anomalías de la temperatura superficial del mar. Por otra parte, estudiaremos las aplicaciones de Parisi, que incluyen su trabajo sobre la resonancia estocástica para explicar la alternancia entre periodos glaciares e interglaciares en nuestro planeta, y su teoría de *spin glasses*, que aplicaremos en la predicción de configuraciones geométricas emergentes en un sistema climático de estanques sobre placas de hielo en el Ártico.

Abstract

Our understanding of the Earth's climate and of humanity's influence on it has advanced significantly in recent decades. In 2021, the Nobel Prize in Physics was awarded to Syukuro Manabe and Klaus Hasselmann for the physical modelling of the Earth's climate, the quantification of climate variability, and the reliable prediction of global warming, and to Giorgio Parisi for the discovery of the interplay between disorder and fluctuations in physical systems across scales ranging from the atomic to the planetary. This was the first Nobel Prize in Physics awarded for research directly related to the climate of our planet and, consequently, to the field of climate science. In this work, we present some of the physical and mathematical foundations underlying the modelling of the Earth's climate as a complex system. On the one hand, we focus on Hasselmann's stochastic climate model and its application to a practical case study involving sea-surface temperature anomalies. On the other hand, we examine several applications of Parisi's work, including stochastic resonance as a mechanism for explaining the alternation between glacial and interglacial periods, and spin-glass theory, which we apply to the prediction of emergent geometric configurations in a climatic system of melt ponds on Arctic sea ice.

1. Introducción.

El objetivo de este trabajo es realizar una revisión bibliográfica con el fin de establecer los principios físicos y matemáticos relacionados con el sistema climático terrestre como sistema complejo. En particular, nuestra meta será analizar las contribuciones de Klaus Hasselmann y Giorgio Parisi en este campo de estudio.

Nuestro trabajo sigue los logros que llevaron al premio Nobel de Física de 2021, que fue otorgado por la *Royal Swedish Academy of Sciences* a Syukuro Manabe, Klaus Hasselmann y a Giorgio Parisi por sus estudios de los sistemas complejos. En particular, como se especifica en el informe divulgativo de Rose, [1], Manabe y Hasselmann comparten una mitad del premio por su trabajo pionero en el desarrollo de modelos climáticos. Por su parte, Parisi recibe la otra mitad del premio por sus soluciones teóricas de gran aplicabilidad en la teoría de sistemas complejos.

Aunque es difícil dar una definición precisa de lo que es un sistema complejo, las descripciones se concentran en dos características particulares. Por una parte están de acuerdo en que son sistemas en los que hay un gran número de componentes que interactúan entre sí, típicamente con comportamientos no lineales. La otra característica principal es la aparición de fenómenos emergentes por la interacción de estas componentes en múltiples escalas espaciales y temporales. Estas descripciones corresponden a las dadas en el artículo de revisión bibliográfica de Ghil de 2020, [2], y en el informe *Scientific Background on the Nobel Prize in Physics 2021* del *Nobel Committee for Physics*, [3]. En este contexto, Parisi aborda teóricamente estos sistemas. Para el caso de sistemas desordenados explica que si la barrera de potencial para llegar a un estado realmente estable es muy alta, el sistema evolucionará lenta y permanentemente por estados metaestables que pueden ser perturbados fuera de su equilibrio. En el artículo de revisión bibliográfica llevado a cabo por Franzke et al, [4], se explica que Hasselmann se enfrenta a los sistemas complejos intentando linealizar y reducir el orden de las ecuaciones que rigen los sistemas. En particular, Hasselmann, que es climatólogo, investiga los sistemas complejos siempre en el contexto del clima terrestre, el sistema complejo por excelencia.

Como se explica en el informe de Bohémier [5], la relación entre los trabajos de Hasselmann y Parisi no resulta inmediata. El artículo de revisión de Franzke et al, [4], explica que Hasselmann se centra en el desarrollo de modelos climáticos estocásticos y en el tratamiento de ruido en el análisis de señales. La carrera académica de Parisi se concentra en el estudio de los *spin glasses*, estructuras que tienen su origen en sistemas concretos de ferromagnetismo. La clave de la relación entre sus trabajos está en la aplicabilidad de los modelos de Parisi al resto de ciencias de sistemas complejos. El clima es un sistema complejo y la teoría de Parisi (si bien es más abstracta) también resulta aplicable en los contextos de climatología en los que Hasselmann desarrolló su carrera. El desarrollo teórico por el que están más estrechamente unidos es el desarrollo de modelos de clima estocásticos (por parte de Hasselmann) y el estudio del fenómeno de resonancia estocástica a escala paleoclimática (por parte de Parisi). Por ser estos modelos el nexo entre ambos científicos, serán también el núcleo de este trabajo.

En este trabajo justificaremos y sintetizaremos la modelización climática a través de la lupa de ambos investigadores, dando una descripción suficiente y accesible en un campo en el que la barrera contextual de entrada es alta porque depende de desarrollos matemáticos no estandarizados y porque tiene un vocabulario y metodologías muy especializados. Reduiremos el nivel de dependencia teórica y contextual para abordar el amplio dominio de los modelos del clima terrestre.

El trabajo se estructura de la siguiente manera. Tras una breve introducción a la modelización climática, se introducen las principales herramientas utilizadas para el análisis y contraste

de modelos climáticos. A continuación se describen los procesos estocásticos y, en particular, se estudian los procesos autorregresivos. Sobre esta base, se desarrolla el modelo estocástico de Hasselmann y se estudian sus propiedades más relevantes. Posteriormente, se describen los sistemas de tipo *spin glass* propuestos por Parisi. Después de haber dado la teoría necesaria se presentan tres aplicaciones representativas: el estudio de las anomalías de temperatura superficial del mar mediante la modelización de Hasselmann, la explicación de los ciclos glaciares e interglaciares a través de la resonancia estocástica y, por último, la modelización de la geometría de los estanques de deshielo en el hielo marino ártico mediante modelos inspirados en la teoría de *spin glasses*.

2. Desarrollo teórico.

En esta sección presentaremos el marco teórico para entender la modelización de fenómenos climatológicos basándonos principalmente en la revisión bibliográfica de Ghil de 2020, [2] y el libro de von Storch y Zwiers, [6].

Antes de hablar de ninguna contribución o modelo concreto, daremos un marco general para entender el clima terrestre sin la necesidad de estar familiarizado con su vocabulario y descripciones habituales. Pensemos en los fenómenos meteorológicos que podemos conocer: borrascas, anticiclones, tormentas, monzones, corrientes oceánicas, el efecto invernadero... Lo cierto es que la cantidad de procesos es tan extensa como podamos imaginar, pero lo importante para entender cómo funcionan es darse cuenta de que todos estos efectos pueden ser descritos por variables termodinámicas (temperatura, presión, densidad...) y dinámicas (velocidad, velocidad angular, potencial gravitatorio...); que todos los fenómenos pueden ser reducidos a la interacción de medios: el océano, la atmósfera, la geosfera...; y que cada fenómeno se desarrolla en una escala temporal y espacial distinta. Los tres hechos son clave en nuestras descripciones del clima terrestre.

En primer lugar abordemos las escalas de los fenómenos. Es esencial darse cuenta que hay fenómenos que van desde la escala de los segundos (como las turbulencias) o las horas (como las tormentas), hasta los años (como el fenómeno El Niño-Oscilación del Sur, ENOS) o millones de años (como las fases de glaciación terrestre). Además, existen fenómenos que pueden abarcar un espacio reducido o que están localizados en una latitud o altitud específica, mientras que otros son completamente globales o abarcan secciones terrestres que implican distintos meridianos o paralelos, etc. Saber en qué escala temporal discurre el fenómeno que modelamos es esencial para tener en cuenta su interacción con el resto de eventos meteorológicos. Por ejemplo, si estamos modelando el movimiento de una parcela de aire de la atmósfera y descubrimos que el movimiento es muy localizado, no tendremos que tener en cuenta el efecto de la fuerza de Coriolis (fruto de la rotación de la Tierra) para obtener una descripción fidedigna del evento.

La combinación entre la formulación termodinámica y dinámica es necesaria. La densidad del medio ρ , la capacidad calorífica a volumen constante C del medio, la concentración de los componentes químicos $\{\xi_k : 1 \leq k \leq K\}$ contenidos en el medio y presentes en diferentes estados, las tres componentes $\{v_i : 1 \leq i \leq 3\}$ del vector velocidad, la temperatura T , la presión p , la tasa de calentamiento J , el potencial gravitatorio Φ , y se debe tener en cuenta el hecho de que el sistema climático está inmerso en un sistema de referencia no inercial que rota con una velocidad angular Ω con componentes $\{\Omega_i : 1 \leq i \leq 3\}$. Con estas variables ya podemos determinar la termodinámica del medio en cada instante a través de la ecuación de estado:

$$\rho = g(T, p, \xi_1, \dots, \xi_K) \quad (1)$$

Respecto a la evolución del sistema, consideramos que hay tres ecuaciones correspondien-

tes a los equilibrios o balances del sistema que, junto con la ecuación de estado, nos dan toda la información del conjunto:

- i). La ecuación de balance de masa para los compuestos químicos constituyentes puede escribirse de la siguiente manera:

$$\partial_t(\rho\xi_k) = -\partial_i(\rho\xi_kv_i) + D_{\xi_k} + L_{\xi_k} + S_{\xi_k}, \quad \forall k \in \{1, \dots, K\}, \quad (2)$$

donde D_{ξ_k} es un término de difusión, L_{ξ_k} es un término asociado a las transiciones de fase del compuesto, y S_{ξ_k} es un balance de masa local debido a otras reacciones químicas asociadas con k .

- ii). El balance de momentos, que corresponde a las ecuaciones de Navier-Stokes:

$$\partial_t(\rho v_i) = -\partial_j(\rho v_j v_i) - \partial_i p + \rho \partial_i \Phi - 2\rho \epsilon_{ijk} \Omega_j v_k + T_i + F_i, \quad \forall i \in \{1, 2, 3\}, \quad (3)$$

donde T_i indica forzamientos mecánicos directos y $F_i = -\partial_j \tau_{ij}$ corresponde a la fricción, siendo τ_{ij} el tensor de estrés o tensiones.

- iii). El balance energético local, como disección del Primer Principio de la Termodinámica ($du = \delta q - \delta w$) y de la energía mecánica del sistema ($E_c = E_{c,CM} + \frac{1}{2}mv^2 = \rho \Delta V (u + \frac{1}{2}v^2)$):

$$\partial_t(\rho e) = -\partial_j(\rho \varepsilon v_j) - \partial_j Q_j^{SW} - \partial_j J_j^{SH} - \partial_j J_j^{LH} - \partial_j Q_j^{LW} - \partial_j(v_i \tau_{ij}) + v_i T_i, \quad (4)$$

donde e es la energía por unidad de masa (energía específica), $\varepsilon = e + \frac{p}{\rho}$ es la entalpía por unidad de masa (entalpía específica), la suma del trabajo realizado por el forzamiento mecánico es $v_i T_i$, y la pérdida de energía viene dada por las divergencias de las componentes de radiación de onda corta (solar) Q^{SW} y onda larga (terrestre) Q^{LW} del vector de Poynting, de los flujos turbulentos de calor sensible J_j^{SH} y calor latente J_j^{LH} , y del producto escalar del campo de velocidad con el tensor de esfuerzo $v_i \tau_{ij}$.

Ser consciente de la escala del fenómeno (temporal y espacial), cuáles son sus actores (océano, criosfera, radiación...) y de qué variables termodinámicas entran en juego es lo que necesitamos en cada caso para modelizar cada fenómeno. Según respondamos a cada pregunta utilizaremos una o varias de las ecuaciones anteriores (que podremos aproximar adecuadamente) para describir la evolución temporal del sistema.

Otra herramienta esencial en el contexto de la física climática es el análisis de Fourier. Para comparar modelos con la realidad, a menudo no podemos comprobar que los resultados dados por el modelo coinciden con los reales porque los datos reales tienen ruido, ya sea por imprecisiones en la medición o porque, como en el caso de la modelización climática estocástica, el efecto de fenómenos de menor escala temporal afecta a las señales en la lectura de las medidas de eventos de mayor duración. El análisis espectral soluciona el problema de contrastar modelos. La idea general es comparar el espectro de los datos reales con el espectro de la solución aportada por el modelo, si ambos coinciden y siguen las mismas tendencias, el modelo será bueno.

Antes de concretar las herramientas de Fourier debemos tener en cuenta ciertas definiciones básicas en el contexto.

La primera definición de nuestro interés es la de un proceso estacionario. Dada una sucesión de variables aleatorias, $\mathbf{X} = (X_t)$, decimos que la secuencia conforma un proceso estacionario si todas las propiedades estadísticas del proceso son independientes del índice t . Es decir, X_t tiene la misma función de distribución para todo t , y para todo t y s , los parámetros de la función de distribución conjunta de X_t y X_s dependen solo de $|t - s|$.

Esta definición puede resultar demasiado estricta cuando tratamos datos reales con ruido aleatorio (por eso hablamos de sucesiones de variables aleatorias). Por eso, podemos relajar la definición y exigir que el proceso sea débilmente estacionario, es decir, que mantenga sus propiedades estadísticas en valor medio. Equivalentemente queremos que se cumplan dos condiciones:

- a). La media del proceso, $\mathbb{E}(X_t)$, es independiente del tiempo t .
- b). Los momentos de segundo orden $\mathbb{E}(X_s X_t)$ son una función únicamente de la diferencia de tiempo $|t - s|$. En procesos con media 0 esto coincide con la covarianza de las variables.

Debemos saber diferenciar qué clase de proceso tenemos según estas características. Si bien es común aproximar procesos como estacionarios, muchas veces es más realista hablar de procesos débilmente estacionarios, que conservan las propiedades estadísticas en todo momento. En realidad, un concepto muy útil es el de procesos débilmente cicloestacionarios, más apropiado para la modelización en general porque nos permite tener en cuenta ciclos que ocurren a lo largo del proceso, como por ejemplo las estaciones del año en la media de temperaturas de un lugar.

Otro elemento de interés es el espectro de un proceso. Este concepto es clave para la caracterización de procesos y para comparar las soluciones de nuestros modelos con los datos reales. Al igual que para otras herramientas matemáticas, observaremos que su definición aplicable depende del contexto y que, realmente, cuando tratamos con datos reales, nos conviene definirlo a través de términos estadísticos. Para un proceso determinista, que representa una señal ideal caracterizada por la función $x(t)$, el espectro se define a través de la transformada de Fourier:

$$\Gamma(\omega) := \mathcal{F}(x)(\omega) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi\omega t} dt. \quad (5)$$

En términos de análisis de fenómenos reales, esto corresponde a una señal ideal, sin ruido. A pesar de no ser un caso realista, es un buen precedente del espectro que vamos a utilizar por ser una función conjugada de la señal original a través de la transformada de Fourier (y que por lo tanto contiene la misma información).

Supongamos ahora que tratamos con una señal real. Como el ruido es aleatorio parece razonable asumir que podemos modelarla a partir de un proceso aleatorio caracterizado por la sucesión $X = (X_t)$, donde cada X_t es una variable aleatoria. Llamamos autocovarianza a la covarianza entre las variables de este mismo proceso, $\gamma(\tau) = \mathbb{Cov}(X_t, X_{t+\tau})$ y definimos su versión adimensional, la autocorrelación:

$$\rho(\tau) = \frac{\gamma(\tau)}{\gamma(0)} = \frac{\mathbb{Cov}(X_t, X_{t+\tau})}{\mathbb{Var}(X_t)}. \quad (6)$$

El argumento τ se denomina retardo (*lag*).

Ahora podemos definir el espectro de la señal como la transformada de Fourier de la autocorrelación:

$$\Gamma(\omega) := \mathcal{F}(\rho)(\omega). \quad (7)$$

La función de autocorrelación se puede interpretar como una medida de lo determinado que está el proceso en el tiempo $t + \tau$ por el tiempo t , equivalentemente, la autocorrelación es una medida de la predictibilidad del proceso. Veremos que podemos caracterizar procesos a través de esta función y, por ser la transformada de Fourier una biyección, podremos caracterizar los procesos a través del espectro. Esto será óptimo porque cada proceso, que está registrado por una señal con ruido, tendrá una huella que podemos comparar en el espacio de Fourier con el

espectro, en la que el ruido aleatorio se transforma en una constante plana y uniforme en el rango de las frecuencias. Del mismo modo, en el espacio de Fourier podremos identificar los periodos como picos en las frecuencias. Una explicación más general y ejemplificada sobre esta caracterización se da en el informe de Ghil del 2002, [7]. En este trabajo daremos una caracterización suficiente para nuestro contexto teórico y sus aplicaciones.

Podremos definir el tiempo característico de un proceso como el tiempo τ_c tal que $\forall \tau \geq \tau_c$ $\rho(\tau) = 0$. Así, un tiempo característico es el tiempo a partir del cual no tenemos información para predecir la evolución de un proceso. Notamos que puede ser infinito, por ejemplo, con procesos periódicos. Sin embargo, en nuestro contexto no encontramos periodos exactos reales sino que tendremos cuasiperiodos. Para nosotros referirnos a la escala temporal del proceso y a su tiempo característico será equivalente, aunque de manera general no tenga que coincidir (como en el caso de procesos deterministas periódicos).

Para utilizar los datos reales en el análisis del proceso (y el posterior contraste con el modelo) no podemos usar las definiciones probabilísticas definidas para variables aleatorias porque realmente tenemos una secuencia de datos. Debemos sustituir la esperanza y covarianza, por sus equivalentes utilizando medias temporales. Esta versión estadística es suficiente cuando elegimos un periodo de tiempo T suficientemente grande para hacer la media temporal, si τ es el tiempo característico del proceso debemos tener $T \gg \tau$. Podemos sustituir esta condición por una hipótesis que mantendremos de ahora en adelante (aunque $T \geq \tau$ necesariamente), esta hipótesis es que se cumple el principio de ergodicidad, que nos permite equiparar las medias temporales a las medias de conjunto del proceso. Es equivalente a decir que calcular la media temporal de la serie observada del proceso es lo mismo que haber obtenido la media de todos los posibles resultados que podía haber tomado físicamente el proceso.

Cuando consideramos un sistema con más de una escala temporal hay que matizar la equivalencia que da la condición ergódica. Para eventos de tiempo característico τ_x (caracterizados por x) que cumplen $\tau_x \ll \tau_y$ (escala temporal de los eventos caracterizados por y) el principio ergódico nos dice que promediar en un tiempo $\mathcal{O}(\tau_x) \leq T \ll \tau_y$ es equivalente a realizar el promediado de conjunto respecto a x . Para un tiempo de promediado $T \geq \mathcal{O}(\tau_y)$ la ergodicidad sería una media de conjunto respecto a las variables x e y .

2.1. Contribuciones de Klaus Hasselmann.

Klaus Hasselmann recibió su participación del premio Nobel de 2021 por su contribución en la modelización del clima terrestre. Uno de sus logros destacados es cuantificar la variabilidad de los procesos climáticos y permitir la correcta predicción del calentamiento global, como se justifica en el artículo divulgativo de Joanna Rose, [1]. Su contribución a la climatología va mucho más allá de la cuantificación del ruido en la recogida de datos y de la optimización de medidas (problema que aborda Hasselmann en sus artículos de 1992 [8], y de 1997 [9]). Nuestro enfoque es el de los modelos climáticos estocásticos que, junto con Claude Frankignoul y Peter Lemke desarrolla en los trabajos revolucionarios en climatología que publica Hasselmann entre 1976 y 1977. Nos referimos al artículo de Hasselmann de 1976, *Stochastic climate models, Part I: Theory*, [10]; a la segunda parte de este artículo publicada por Hasselmann y Frankignoul, [11]; y a la tercera parte de este artículo publicada por Peter Lemke, [12].

Antes de hablar de modelización aclaramos ciertos conceptos que serán útiles más tarde, basándonos de nuevo en el libro de von Storch y Zwiers, [6].

Un proceso estocástico se define formalmente dentro del contexto de teoría de la medida en probabilidad. Obviando los detalles matemáticos, definimos un proceso estocástico como una sucesión de variables aleatorias definida en un conjunto indexado $\mathbb{T}$, que típicamente representa el tiempo y será $\mathbb{T} \subseteq \mathbb{N}$ para modelos discretos o $\mathbb{T} \subseteq \mathbb{R}$ para modelos continuos.

Denotamos $X = (X_t)_{t \in \mathbb{T}}$ al proceso estocástico donde, para cada $t \in \mathbb{T}$, X_t es una variable aleatoria del espacio de probabilidad pertinente.

Si bien por la definición no es evidente, podemos encontrar procesos estocásticos continuos. El ejemplo más recurrente es el del movimiento de los granos de polen sobre el agua. El botánico Robert Brown describió este proceso que hoy llamamos movimiento browniano como un desplazamiento que si bien es continuo, es errático y aleatorio. Este tipo de movimientos caóticos forman la clase de procesos que trataremos, otros ejemplos que a día de hoy son más cotidianos de esta clase de procesos son el valor de los activos en el mercado financiero o, como veremos, el tiempo meteorológico en escalas climáticas. En este trabajo dos tipos de procesos estocásticos tienen una importancia especial:

- i). Los procesos de Markov. Su descripción matemática excede el marco de este trabajo, pero podemos dar una definición reducida. En el contexto discreto corresponde a un proceso que cumple la propiedad:

$$\mathbb{P}(X_n | X_{n-1} = x_{n-1}, \dots, X_1 = x_1) = \mathbb{P}(X_n | X_{n-1} = x_{n-1}), \forall n, \quad (8)$$

que se puede interpretar como que el proceso tiene una “memoria” limitada. En un caso continuo suficientemente simple, podemos decir que son procesos estocásticos gaussianos de media 0 que tienen matriz de covarianzas definida por $\text{Cov}(X_s, X_t) = A \cdot e^{-\lambda|t-s|}$, los factores A y λ serían modulaciones en la memoria del proceso. Un resultado que debemos saber es que las soluciones de la ecuación de Fokker-Planck son procesos de Markov, hecho que se justifica en la sección VI.2.2 de los apuntes de Cyril Labbé, [13].

- ii). Procesos de ruido blanco. Un proceso estocástico se dice que es ruido blanco si todas sus componentes forman una sucesión de variables aleatorias de media cero con misma varianza. Esta clase de procesos se dice que no tiene memoria porque, por construcción, en cada instante t , el valor del proceso X_t es independiente del valor en cualquier otro instante (su función de autocorrelación es 1 en $\tau = 0$ y nula en el resto de puntos). El espectro del ruido blanco es una constante (que coincide con su varianza). Típicamente son procesos gaussianos pero podemos extender su definición a otros procesos de media cero y varianza constante.

Otra clase de procesos importante es la de los procesos autorregresivos (o AR). Estos procesos estocásticos son las soluciones de las versiones discretizadas de una ecuación diferencial de orden p con un término de ruido blanco. Dada una ecuación diferencial

$$\sum_{j=1}^p a_j \frac{d^j x(t)}{dt^j} + a_0 x(t) = z(t), \quad (9)$$

donde z es un forzamiento externo y a_j es una constante $\forall j \in \{0, \dots, p\}$, si aproximamos las derivadas por el método de diferencias finitas en un conjunto de tiempo $\mathbb{T} \subseteq \mathbb{N}$, nos queda la expresión

$$X_t = \alpha_0 + \sum_{j=1}^p \alpha_j X_{t-j} + Z_t. \quad (10)$$

La ecuación (10) define a un proceso autorregresivo de orden p , $X = (X_t)_{t \in \mathbb{T}}$ si la discretización de la función z admite su interpretación como un ruido blanco. Las constantes α_j son constantes determinadas por los coeficientes originales de la ecuación diferencial y el proceso Z_t es la función z en su forma discreta y reescalada. Hemos dado la definición en una dimensión por simplicidad pero si x fuera un vector, $\mathbf{x}$, el proceso X también sería vectorial, $\mathbf{X}$.

Los procesos autorregresivos más importantes son los de orden 1 y 2 porque el espectro de un proceso $AR(p)$ puede ser expresado como la suma apropiada de espectros de procesos de órdenes 1 y 2. De los procesos $AR(1)$ necesitamos saber que son procesos amortiguados y que su función de autocorrelación nos da una medida del factor de amortiguación del proceso. Los procesos $AR(2)$ pueden tener comportamientos oscilatorios o amortiguados que dependen de los parámetros que definan el proceso. Antes de dar el espectro de los procesos autorregresivos, nos damos cuenta de que lo debemos definir a través de la autocorrelación del proceso en el tiempo porque son procesos aleatorios (la ecuación que los define tiene un término de ruido blanco).

Una característica de los procesos $AR(p)$ es que es fácil demostrar algebraicamente que es equivalente conocer el proceso a conocer su función de autocorrelación. Si multiplicamos un proceso $AR(p)$ en el instante $t \geq p$, X_t , por los eventos $X_{t-\tau}$, para $\tau = 1, \dots, p$,

$$X_t X_{t-\tau} = \sum_{i=1}^p \alpha_i X_{t-i} X_{t-\tau} + Z_t X_{t-\tau}, \quad (11)$$

podemos obtener un sistema de ecuaciones completamente determinado si tomamos la esperanza de esta expresión. Este sistema relaciona la función de autocovarianza con los coeficientes α_j que determinan el proceso. En la sección 11.1.6 del libro de von Storch y Zwiers, [6], se justifica la solución del sistema $\forall t \in \mathbb{T}$. Como sabemos que existe, podemos afirmar que cualquier proceso AR está completamente determinado por su función de autocovarianza y, por lo tanto, también está completamente determinada por el espectro (transformada de Fourier de la autocorrelación).

En la sección 11.2 del libro de von Storch y Zwiers, [6], se justifica que el espectro de un proceso $AR(p)$ tiene la forma

$$\Gamma(\omega) = \frac{\sigma_Z^2}{\left| 1 - \sum_{j=1}^p \alpha_j e^{-2\pi i j \omega} \right|^2}, \quad (12)$$

donde σ_Z^2 es la varianza del proceso de ruido blanco Z . En particular, para procesos autorregresivos de orden 1 queda la ecuación:

$$\Gamma_{AR(1)}(\omega) = \frac{\sigma_Z^2}{|1 - \alpha_1 e^{-2\pi i \omega}|^2} = \frac{\sigma_Z^2}{1 + \alpha_1^2 - 2\alpha_1 \cos(2\pi\omega)}, \quad (13)$$

que no tiene extremos porque $\frac{d}{d\omega} \Gamma_{AR(1)}(\omega) = -2\alpha_1 \Gamma_{AR(1)}(\omega)^2 \sin(2\pi\omega) \neq 0$ para $\omega > 0$. El espectro de los procesos $AR(1)$ se caracteriza entonces por el signo del coeficiente α_1 . Si $\alpha_1 > 0$, el “pico espectral” se localiza en la frecuencia $\omega = 0$, que en términos del tiempo t quiere decir que la varianza del proceso se localiza en tiempos largos¹. Estos procesos a menudo se denominan procesos de ruido rojo, su espectro lo encontramos en la figura 1. Los procesos $AR(1)$ con $\alpha_1 < 0$, son procesos de ruido azul, tienen poca importancia práctica en la investigación climática porque tienden a cambiar de signo en cada paso de tiempo. En la mayoría de los contextos de la investigación climática, el proceso observado evoluciona de manera continua.

Podemos caracterizar el espectro de los procesos de Markov por el espectro del proceso autorregresivo equivalente. En las secciones 10.3.1, 10.3.6 y 10.4.3 del libro de von Storch y Zwiers, [6], se justifica que los procesos de Markov son equiparables a un proceso autorregresivo de orden 1. Consecuentemente, estos procesos están caracterizados por su espectro y

¹ Esto quiere decir que el proceso integra el ruido blanco y en tiempos característicos del proceso da una respuesta al sistema, lo explicaremos en profundidad en el teorema de modelización estocástica.




Fig. 1: Espectros de los procesos AR(1) con coeficientes $\alpha_1^L = 0,3$ y $\alpha_1^R = 0,9$. Figuras extraídas del capítulo 11.2 del libro de von Storch y Zwiers, [6]. En (a) el eje para α_1^L es el izquierdo y para α_1^R el derecho, en (b) se muestra el espectro en escala logarítmica, donde la curva con α_1^L es la de menor potencia.

tienen también un espectro rojo o azul en función de sus parámetros. Los procesos que veremos serán de espectro rojo, como los de la figura 1. Para procesos estocásticos generales nos debemos conformar con la justificación de la caracterización por la autocorrelación que ya hemos hecho para procesos autorregresivos.

Con el contexto matemático suficiente, abordamos los modelos de clima estocásticos propuestos por Hasselmann en su artículo de 1976 *Stochastic climate models. Part I. Theory*, [10]. Antes de considerar un caso particular (que veremos en la sección de resultados, la sección 3), consideramos un fenómeno general caracterizado por las variables termodinámicas y dinámicas $\mathbf{z}$. Hacemos una descomposición de $\mathbf{z}$ según la escala temporal de sus componentes $\mathbf{z} = (\mathbf{x}, \mathbf{y})$. En este modelo $\mathbf{x}$ representa las variables con un tiempo característico τ_x significativamente menor que el de las variables $\mathbf{y}$, τ_y ; luego $\tau_x \ll \tau_y$. Suponemos conocidas las ecuaciones de evolución del sistema (que corresponderán a algún balance de entre las ecuaciones (2), (3) o (4)),

$$\frac{d\mathbf{z}}{dt} = f(\mathbf{x}(t), \mathbf{y}(t)) \implies \begin{cases} \frac{d\mathbf{x}^j}{dt} = u^j(\mathbf{x}(t), \mathbf{y}(t)) \\ \frac{d\mathbf{y}^j}{dt} = v^j(\mathbf{x}(t), \mathbf{y}(t)) \end{cases} \quad \forall j, \quad (14)$$

donde f (y $u^j, v^j \forall j$) típicamente es una expresión no lineal. Nos fijamos en las aproximaciones que podemos hacer para conocer el estado final del sistema. Si quisiéramos modelar la evolución de los procesos cuya escala temporal es τ_x , está claro que simplemente necesitamos mantener las variables $\mathbf{y}$ constantes. En este contexto podríamos realizar predicciones en tiempos (mucho) menores que τ_y . Sin embargo, queremos dar la evolución global del proceso a largo plazo, $t > \tau_y$, y tenemos que tener en cuenta la evolución de $\mathbf{y}$. La aproximación más sencilla que se puede hacer sigue este razonamiento: los eventos de corto plazo (rápidos) no tienen efectos en los de largo plazo (lentos) porque la media temporal de los primeros en tiempos grandes tiende a 0. Este razonamiento que se traduce en que eventos meteorológicos no afectan a la evolución del clima era el estándar en climatología hasta la investigación de Hasselmann en modelos estocásticos, que demuestra lo contrario. Nuestra hipótesis para la modelización es que los eventos de menor escala temporal pueden ser tratados como un forzamiento aleatorio que aparece en nuestra ecuación de evolución del sistema, de este modo, tratamos los eventos caracterizados por $\mathbf{x}$ como un proceso estocástico $(\mathbf{X}_t)_{t \in \mathbb{T}}$.

Si solo tenemos esto en cuenta podríamos modelizar ya este sistema climático, pero no es

suficiente. Nos referiremos al siguiente resultado como teorema de modelización estocástica y lo caracterizaremos a través de la ecuación (15):

Dado un sistema con dos escalas temporales de magnitud significativamente distintas, $\tau_x \ll \tau_y$, podemos modelar su evolución temporal en escalas temporales grandes ($t \gg \tau_x$, $t \geq \mathcal{O}(\tau_y)$) a través de un modelo estocástico en el que las magnitudes que caracterizan el proceso rápido $\mathbf{x}(t) \mapsto \mathbf{x}_t$ se interpretan como ruido blanco. Además, en cada instante el sistema responde al término estocástico con un término que equilibra la ecuación diferencial original del sistema.

Equivalentemente, para $t \geq \mathcal{O}(\tau_y) \gg \tau_x$ se cumple:

$$\frac{d\mathbf{z}}{dt} = f(\mathbf{x}(t), \mathbf{y}(t)) \quad \mapsto \quad \frac{d\mathbf{z}}{dt} = f(\mathbf{x}_t, \mathbf{y}(t)) + g(\mathbf{y}(t)), \quad (15)$$

donde g es la función de respuesta al forzamiento estocástico $\mathbf{x}_t$.

Demostración:

En todo el desarrollo $t \gg \tau_x$. Recordamos además que la evolución del sistema viene determinada por la ecuación (14)

Debemos simplificar bastante esta demostración. Para facilitar el desarrollo matemático posterior, se trabaja con las variaciones o anomalías de las variables, las definimos para cada componente z^j (que incluye x^j , y^j), u^j y v^j . Comenzamos por definir la desviación $\delta z_t^j := z_t^j - z_0^j$. La anomalía será definida como $\tilde{z}_t^j = \delta z_t^j - \langle \delta z_t^j \rangle$. Por la hipótesis ergódica, podemos calcular $\langle \delta z_t^j \rangle$ como la media de conjunto o como la media temporal en un periodo $\tau_x \ll T \ll \tau_y$, esto es necesario porque necesitamos que la media sea consistente con las componentes rápidas y lentas del proceso.

Con estas definiciones podemos centrarnos en resolver la ecuación diferencial estocástica:

$$\frac{d\tilde{y}^j}{dt} = v^j(\mathbf{x}_t, \mathbf{y}) - \langle v^j \rangle =: \tilde{v}^j, \quad (16)$$

lo justificaremos más tarde, pero veremos que la escala temporal de $\tilde{v}^j$ es la misma que la de $\mathbf{x}_t$. Es fácil notar que $\tilde{v}_t^j$ es un proceso estocástico $\forall j$ porque depende del proceso estocástico $\mathbf{x}_t$.

Otras definiciones que usaremos a lo largo de la demostración serán:

$$\begin{aligned} \gamma_{jk}(\tau) &= \text{Cov}(y_t^j, y_{t+\tau}^k) \\ D^{jk} &= \int_{-\infty}^{+\infty} \text{Cov}(v_t^j, v_{t+\tau}^k) d\tau \\ \tilde{V}^j(\omega) &= \mathcal{F}(\tilde{v}^j)(\omega) \\ F^{jk}(\omega) &= \text{Cov}(\tilde{V}^j(\omega), \tilde{V}^k(\omega)) \equiv \text{es un símil del espectro de } \tilde{v}^j \\ G^{jk}(\omega) &= \mathcal{F}(\text{Cov}(\tilde{y}^j, \tilde{y}^k))(\omega) \stackrel{[6]}{=} \mathcal{F}(\gamma_{jk})(\omega) \\ &\equiv \text{símil del espectro del proceso largo, y.} \end{aligned} \quad (17)$$

Como hemos dicho que asimilaremos $\tilde{v}^j$ a la escala temporal de $\mathbf{x}$, podremos decir que F^{jk} corresponde al espectro del forzamiento (que también llamaremos *input* del sistema), mientras que G^{jk} corresponde a la respuesta del proceso largo.

Nuestro objetivo será ver que el espectro del proceso es un proceso amortiguado rojo, un proceso amortiguado sin divergencias, con un pico inicial cuya potencia caracteriza el forzamiento (ruido estocástico) del proceso. Para demostrar el resultado bastará ver que para una función de la forma $f(\mathbf{x}_t, \mathbf{y}(t)) + g(\mathbf{y}(t))$, $\forall t \gg \tau_x$ obtenemos el espectro rojo.

Todavía bajo la hipótesis de que $\tau_x \ll \tau_y$ asumimos también que $\delta y^j, \gamma^{jk}(\delta t) \propto \delta t \forall j, k$. En el artículo de Hasselmann del 1976, [10], se justifica que bajo estas hipótesis la distribución de probabilidad de $\mathbf{y}$, $p(\mathbf{y}, t)$, sigue la ecuación de Fokker-Planck:

$$\frac{\partial p}{\partial t} + \frac{\partial}{\partial y^j}(\hat{v}^j p) - \frac{\partial}{\partial y^j} \left(D^{jk} \frac{\partial p}{\partial y^k} \right) = 0, \quad (18)$$

donde γ^{jk} es la función de covarianza entre y^j e y^k , D^{jk} es el término de difusión (definido como antes) y $\hat{v}^j = \frac{\langle \delta y^j \rangle}{\delta t} - \frac{\partial D^{jk}}{\partial y^j}$ (por resultados de análisis de Fourier, correspondería a una especie de transformada de Legendre de $\langle v^j \rangle$). El hecho de que los términos de difusión estén en la EDP de la distribución de probabilidad implica que la variabilidad del proceso aumente indefinidamente. Por este motivo es necesario añadir un término a la ecuación diferencial que rige el movimiento. Esta es la justificación matemática del término de equilibrio que añadimos a la ecuación original, pero la realidad es que hay un argumento físico muy razonable: ante el forzamiento que sufren las variables y^j por los eventos caracterizados por $\mathbf{x}$, el sistema y las variables del proceso de mayor escala y responden buscando un equilibrio en cada momento. Por este motivo necesitamos que la ecuación sea de la forma:

$$\frac{d\mathbf{z}}{dt} = f(\mathbf{x}_t, \mathbf{y}(t)) + g(\mathbf{y}). \quad (19)$$

En estas condiciones el proceso de largo plazo, $\mathbf{y}$, es débilmente estacionario porque sus propiedades estadísticas se rigen por la ecuación de Fokker-Planck y por esta ecuación compensada. Después demostraremos que si este término no es añadido la solución diverge para tiempos $t > \tau_y$ (y no sería aplicable el modelo que hemos construido para predecir la realidad en tiempos $t > \tau_y$). A dicho término de compensación le llamamos el término de *feedback*.

Asumiremos en la demostración que el término de *feedback* tiene un comportamiento lineal, por simplicidad y porque es suficiente para la modelización al orden que queremos. Luego:

$$\frac{dy^j}{dt} = v^j(\mathbf{x}_t, \mathbf{y}(t)) + V^{jk} \cdot y^k, \quad (20)$$

y

$$\frac{d\tilde{y}^j}{dt} = \tilde{v}^j(\mathbf{x}_t, \mathbf{y}(t)) + V^{jk} \cdot \tilde{y}^k. \quad (21)$$

Se cumple que $\tilde{v}^j(t + \tau)$ e $y^j(t)$ (e $\tilde{y}^j$) no están relacionadas entre sí para $\tau > 0$ porque la escala temporal del forzamiento aleatorio es infinitamente pequeña en comparación con la de la respuesta al forzamiento. Así, $\tilde{v}^j$ es interpretada como un término aleatorio débilmente estacionario con propiedades estadísticas semejantes a las de $\mathbf{x}$ y, en la aproximación por diferencias finitas para un paso de tiempo Δt :

$$\tilde{y}^j(t + \Delta t) - \tilde{y}^j(t) = V^{jk} \tilde{y}^k(t) \Delta t + Z^j, \quad (22)$$

donde Z^j representa el forzamiento aleatorio continuo integrado durante el incremento de tiempo Δt ($Z^j = \int_t^{t+\Delta t} \tilde{v}^j(s) ds$, donde notamos que en este intervalo, $t + s > t$, $s \in (0, \Delta t)$, se tiene el comportamiento de $\tilde{v}^j(t + s)$ como ruido blanco porque está decorrelacionado de y^j). Reordenando apropiadamente tenemos un

proceso autorregresivo de orden 1:

$$\tilde{y}^j(t + \Delta t) = \sum_{k \neq j} V^{jk} \tilde{y}^k(t) + (V^{jj} + 1) \tilde{y}^j(t) + Z^j, \quad (23)$$

que es claramente un proceso AR(1) con $\alpha_0 = \sum_{k \neq j} V^{jk} \tilde{y}^k(t)$, $\alpha_1 = 1 + V^{jj}$ y término de forzamiento Z^j .

Por las observaciones sobre el espectro de los procesos AR(1) queda demostrado que este proceso tiene un espectro rojo (la condición suficiente para afirmarlo dependerá del modelo exacto, tal y como lo hemos definido aquí, si la matriz de la respuesta lineal V^{jk} es definida positiva se cumple). Por lo tanto, el modelo con el término de *feedback* es adecuado para estimaciones en $t \geq \tau_y$, porque coincide con el espectro de la señal real.

Para entender mejor el papel del término de *feedback*, demostremos que si no lo hubiéramos añadido la solución divergiría en tiempos grandes (o frecuencias pequeñas).

Demostración:

Sin el término de *feedback* el sistema se rige por la ecuación

$$\frac{d\tilde{y}^j}{dt} = \tilde{v}^j. \quad (24)$$

En este caso, no podemos hacer la aproximación por procesos autorregresivos porque el proceso no será equivalente. Debemos calcular manualmente el espectro de y para demostrarlo.

Utilizando la ecuación (24) y las definiciones del comienzo de la demostración encontramos:

$$\tilde{y}^j = \int_{-\infty}^{+\infty} \frac{\tilde{V}^j(\omega)}{i\omega} e^{i\omega t} d\omega - \int_{-\infty}^{+\infty} \frac{\tilde{V}^j(\omega)}{i\omega} d\omega, \quad (25)$$

por lo que, sabiendo además que $F^{jk}(\omega) = \mathbb{Cov}(\tilde{V}^j(\omega), \tilde{V}^k(\omega))$, se obtiene:

$$\begin{aligned} \gamma^{jk}(t) &= \mathbb{Cov}(\tilde{y}^j(t), \tilde{y}^k(t)) \\ &= \int_{-\infty}^{+\infty} \mathbb{Cov}(\tilde{V}^j(\omega), \tilde{V}^k(\omega)) \frac{(e^{i\omega t} - 1)(e^{-i\omega t} - 1)}{(i\omega)(-i\omega)} d\omega \\ &= \int_{-\infty}^{\infty} \frac{F^{jk}(\omega)}{\omega^2} 2(1 - \cos(\omega t)) d\omega. \end{aligned} \quad (26)$$

Esto nos permite afirmar que el espectro (cruzado) de y , que es la transformada de Fourier de la expresión anterior, sigue una expresión proporcional a $\frac{F^{jk}(\omega)}{\omega^2}$ lejos de $\omega \approx 0$, por lo que para $\tau_y \gg t \gg \tau_x$ tenemos:

$$G^{jk}(\omega) \propto \frac{\mathbb{Re}\{F^{jk}(\omega)\}}{\omega^2}. \quad (27)$$

La ecuación (27) es cierta porque $\mathcal{F}(1)(\nu) = 2\pi\delta(\nu)$ (por lo que el término constante solo producirá una constante que aparece en $\omega = 0$) y porque el coseno aporta

$$\mathcal{F}(\cos(\omega t))(\nu) = \pi[\delta(\nu - \omega) + \delta(\nu + \omega)], \quad (28)$$

por lo tanto,

$$\mathcal{F}\left(2\frac{1 - \cos(\omega t)}{\omega^2}\right) = \frac{2}{\omega^2} (2\pi\delta(\nu) - \pi\delta(\nu - \omega) - \pi\delta(\nu + \omega)). \quad (29)$$

Usando que la parte real de F^{jk} es simétrica y su parte imaginaria es antisimétrica (se justifica en los apartados 11.3.3 y 11.4.3 del libro de von Storch y Zwiers,[6], en la definición del espectro cruzado) tenemos que G^{jk} es proporcional a la fracción $\frac{\Re\{F^{jk}(\omega)\}}{\omega^2}$ para $\tau_y \gg t \gg \tau_x$. Esta última condición es equivalente a afirmar $\tau_y^{-1} \ll \omega \ll \tau_x^{-1}$.

Ya casi tenemos el espectro caracterizado como queremos, para frecuencias ω suficientemente pequeñas podemos considerar la serie de Taylor de primer orden de

$$F^{jk}(\omega) = F^{jk}(0) + \omega \cdot \left. \frac{d}{dt} [\mathcal{F}(\text{Cov}(\tilde{v}^j(t), \tilde{v}^k(t+\tau)(\tau)))](\omega) \right|_{\omega=0} + \mathcal{O}(\omega^2), \quad (30)$$

pero como la transformada tiene la forma:

$$\int_{-\infty}^{\infty} \text{Cov}(\tilde{v}^j(t), \tilde{v}^k(t+\tau)) e^{-i\omega t} d\tau \stackrel{\omega \sim 0}{\approx} \int_{-\infty}^{\infty} \text{Cov}(\tilde{v}^j(t), \tilde{v}^k(t+\tau)) d\tau \quad (31)$$

por el teorema fundamental del cálculo

$$\left. \frac{d}{dt} [\mathcal{F}(\text{Cov}(\dots))](\omega) \right|_{\omega=0} \propto (\text{Cov}(\tilde{v}^j(t), \tilde{v}^k(t+\infty)) - \text{Cov}(\tilde{v}^j(t), \tilde{v}^k(t-\infty))), \quad (32)$$

pero como $\text{Cov}(\tilde{v}^j(t), \tilde{v}^k(t \pm \infty)) = 0$ porque no hay periodicidad en los datos reales y no son deterministas (hay cuasiperiodicidad, que no es determinista), entonces el término de orden 1 en frecuencias cercanas a 0 es aproximadamente $F^{jk}(\omega) \approx F^{jk}(0)$ y $G^{jk}(\omega) \approx \frac{F^{jk}(0)}{\omega^2}$. Ahora podemos escribir, de manera aproximada, cómo será el espectro del proceso y para $\omega \ll \tau_x^{-1}$ (equivalentemente, $t \gg \tau_x$):

$$G^{jk}(\omega) = \begin{cases} \frac{F^{jk}(0)}{\omega^2} & \text{si } \omega \leq \mathcal{O}(\tau_y^{-1}), \\ \frac{\Re\{F^{jk}(\omega)\}}{\omega^2} & \text{si } \tau_y^{-1} \ll \omega \ll \tau_x^{-1}. \end{cases} \quad (33)$$

El espectro de este proceso nos revela lo que buscábamos, para frecuencias pequeñas $\omega \leq \mathcal{O}(\tau_y^{-1})$, o lo que es equivalente, para tiempos largos $t \geq \mathcal{O}(\tau_y)$, ¡el espectro diverge! Esto ocurre porque $\frac{1}{x^2}$ diverge cerca del 0 y no es integrable en este dominio. El significado físico de que el espectro diverja para el proceso caracterizado por la ecuación diferencial (24) (el sistema sin el término de *feedback*) es que este proceso no es ni estacionario ni débilmente estacionario ni tiene un espectro rojo (que es el espectro de los datos reales). El espectro resultante se ilustra en la figura 2, donde se comprueba que el espectro del proceso diverge para frecuencias pequeñas y que no representa fielmente la realidad. El régimen caracterizado por la ecuación (24) es insuficiente para tiempos largos.

Queda demostrado que el uso de modelos climáticos estocásticos es útil y cómo debe plantearse dicha modelización.

Para terminar la sección, daremos dos reflexiones adecuadas:

La primera surge por esta cita de Michael Ghil en su revisión bibliográfica del 2020, [6]:

«Stochastic Climate Models can not be used to reproduce a physical system in detail. Nevertheless, they are instrumental in the understanding of the dynamics that prevail in complex general circulation models or observations».

Esta cita nos recuerda el valor real de la modelización, que no pretende replicar la realidad, sino entenderla. Nos servimos de los modelos para profundizar en la realidad de los procesos




Fig. 2: Espectro del proceso y si no consideramos el término de *feedback*. El espectro del *input* (el forzamiento), F^{ij} , se calcula en el artículo de Hasselmann de 1976, [10]. Figura extraída del artículo *Stochastic climate models. Part 1. Theory* de Hasselmann, [10].

y poner a prueba el límite de nuestro entendimiento de los conceptos subyacentes. Mientras que podemos aspirar a unificar las leyes de la naturaleza y dar una descripción total de la realidad, en disciplinas como la climatología, sin una comprensión específica del fenómeno que se modela, un modelo general resulta casi siempre ineficiente. Sabiendo que en la física del clima hay escalas temporales y espaciales que varían en órdenes inmensos de magnitud y que en todas las escalas ocurren procesos que nos interesan para la comprensión del clima terrestre (desde turbulencias localizadas en un punto del espacio que duran segundos hasta los periodos de glaciación de la Tierra entera, separados por millones de años entre sí); es necesario dar modelos específicos para el fenómeno de interés en cuestión, comprender en profundidad las relaciones entre los actores del proceso y, de manera imprescindible, saber qué factores desestimar para facilitar la computación y comprensión del modelo. Todos estos factores son clave para obtener modelos físicos que nos ayuden a entender el clima y su física asociada en mayor profundidad.

La segunda observación es sobre la naturaleza de la modelización estocástica. En primer lugar podemos ver que es un gran ejemplo de la reflexión anterior, porque es esta modelización la que nos permite comprender y demuestra que el tiempo meteorológico tiene un efecto a escala climática (el modelo revela el efecto que los eventos a corto plazo producen sobre los eventos a largo plazo, hecho que no se comprendía hasta la publicación del artículo de Hasselmann de 1976, [10]). Por otra parte nos damos cuenta de que la realidad que descubre no se aleja de nuestros conocimientos matemáticos habituales, los fenómenos de escala meteorológica pueden corresponder a una función que se acerca asintóticamente a cero y el proceso climatológico largo actúa como una integral que concatena el efecto de los procesos cortos y produce una respuesta que no es despreciable. El proceso largo aparece exactamente porque el efecto combinado de estos eventos pequeños tiene un resultado no nulo, lo que convierte al proceso de largo plazo en una analogía física del cálculo integral.

2.2. Contribuciones de Giorgio Parisi.

La Real Academia Sueca de Ciencias decidió darle a Giorgio Parisi la mitad del premio Nobel de Física de 2021 por su contribución en la modelización de sistemas complejos. De su trayectoria académica destaca su trabajo sobre los *spin glasses*. Estas estructuras se caracterizan por ser sistemas complejos con frustración, es decir, sistemas complejos en los que la configuración del sistema no puede organizarse de manera óptima. En esta sección nos centra-

remos en introducir esta clase de estructuras y su caracterización termodinámica, basándonos en los primeros tres capítulos del libro de Nishimori [14] y en el informe de Parisi, [15]. Daremos una explicación reducida de la investigación principal de Parisi, que si bien es de gran interés general para la teoría de sistemas complejos, tiene consecuencias más básicas y no es tan patente en modelización climática. La intersección más evidente entre la investigación de Hasselmann y de Parisi es la resonancia estocástica, que consiste en la modelización del forzamiento aleatorio de un sistema y fue investigada por Parisi en el artículo de Benzi et al, [16].

El *spin glass* es una estructura que se estudia primero en el contexto de aleaciones de metales, por ejemplo, átomos de hierro en una lámina de cobre. En este ejemplo la presencia del hierro cambia las propiedades magnéticas del material original y aparecen comportamientos ferromagnéticos frustrados. Clásicamente, cuando caracterizamos el magnetismo de un enlace por su momento de espín, consideramos materiales ferromagnéticos en los que los momentos de espín están alineados; o bien antiferromagnéticos, en el que el espín está orientado de forma perfectamente antiparalela (direcciones de espín opuestas sucesivas) y no habría magnetismo neto en el material. En un *spin glass* la orientación del espín magnético de cada átomo es aleatoria y esto genera situaciones en las que el espín de algún átomo no tiene una orientación óptima definida. Restringiremos el estudio a una malla de $n \times n$ átomos y cada punto de la malla tendrá asociada una componente de espín positiva o negativa ($s_j = \pm 1$) y solo interactuará con sus vecinos más próximos (los 4 nodos adyacentes). En este caso, si consideramos ahora un punto intermedio es fácil encontrar un estado de frustración. Si tenemos dos enlaces con átomos de espín positivo y dos enlaces con átomos de espín negativo, el átomo central no tendrá una configuración óptima y, siendo positivo o negativo, llevará al sistema a una configuración que llamamos frustrada. Lo que la frustración implica en el sistema físico es la no existencia de un estado fundamental puro del sistema. La clave del trabajo de Parisi es la demostración de estados puros emergentes en este tipo de estructuras. El hamiltoniano de un sistema como el anterior se puede escribir como:

$$\mathcal{H} = - \sum_{\langle j, k \rangle} J_{jk} s_j s_k, \quad (34)$$

donde J_{jk} son los coeficientes de acoplamiento o interacción entre los átomos j y k de la malla y son variables aleatorias que pueden permanecer o no constantes durante la evolución del sistema. La expresión $\langle j, k \rangle$ en el sumatorio quiere decir que la suma se realiza únicamente para los nodos adyacentes. En el caso más sencillo, los coeficientes de interacción permanecen constantes y siguen una distribución de probabilidad gaussiana. El avance teórico que propone Parisi consiste en calcular los estados puros (que corresponden a los estados fundamentales del sistema) a través de réplicas. Una réplica es un estado de configuración equivalente al estado original, es decir, un estado en que los coeficientes de interacción se mantienen constantes mientras que tenemos una distribución aleatoria de los valores de espín de los átomos. Usando parámetros de orden adecuados (distintos de los del sistema de la configuración original), Parisi consigue determinar las propiedades termodinámicas del sistema a través de los promedios configuracionales de las réplicas. Además, consigue explicar la existencia de los estados emergentes relacionándolos con rupturas de la simetría entre réplicas. Esto quiere decir que si a y b son dos réplicas de nuestro sistema original, el hamiltoniano de las réplicas debe ser simétrico ante pequeñas perturbaciones, es decir:

$$\mathcal{H} = \mathcal{H}_a + \mathcal{H}_b + \varepsilon \sum_{j=1}^{n^2} s_a(j) s_b(j) \quad (35)$$

debe ser simétrico respecto a a y b . En el informe de Parisi de 1983, [15], se demuestra cómo las rupturas de simetría de réplicas son el equivalente matemático de infinitos estados termodinámicos puros emergentes en el límite termodinámico de volumen infinito.

La contribución de Parisi, si bien tiene una notación más cercana a la física estadística, es profundamente más teórica que la de Hasselmann y la aplicabilidad que tiene por sí sola en la modelización climática terrestre es limitada. Por eso, en cada modelo climático basado en el marco teórico de Parisi veremos que la evaluación del modelo se realiza en términos distintos (a diferencia de la contribución Hasselmann que podíamos evaluar en la mayoría de casos a través del espectro de la evolución temporal). Es por este motivo que, en lugar de demostrar la aplicabilidad del modelo viendo que replica el espectro de algún fenómeno, nos limitaremos a ver que el modelo funciona en alguna aplicación práctica (sección 3.3). La analogía estructural del modelo y su capacidad de predecir fenómenos emergentes es en realidad lo que justifica la aplicación de este marco teórico en modelización de sistemas climáticos complejos.

3. Resultados y discusión.

En esta sección aplicaremos los desarrollos de Hasselmann y Parisi en ejemplos específicos de sistemas climáticos. Comenzaremos por explicar un modelo estocástico para las anomalías en la temperatura superficial del mar, que fue desarrollado por Hasselmann y Frankignoul, [11]. El segundo ejemplo versa sobre la alternancia entre periodos glaciares e interglaciares en la Tierra con ayuda también de la modelización estocástica, este modelo fue la única contribución directa de Parisi a las ciencias del clima. El tercer ejemplo presentado describe la configuración de estanques sobre bloques de hielo en el océano Ártico, un sistema que tiene especial relevancia por su efecto en el albedo terrestre.

3.1. Temperatura superficial del mar.

La primera aplicación práctica del desarrollo teórico de la sección 2 será la predicción de las anomalías en la temperatura superficial del mar. En el artículo de Hasselmann y Frankignoul, [11], se aplica el modelo estocástico para entender estas anomalías de la temperatura superficial del mar en latitudes medias. A lo largo del artículo, se explica la modelización termodinámica elegida y se resume la exposición del modelo estocástico, cuyos datos simulados se contrastan con los datos extraídos de barcos meteorológicos en distintas regiones. Explicamos aquí el contexto físico y damos el contraste con los datos para un barco que estuvo situado en el Atlántico Norte, el barco meteorológico oceánico India, con coordenadas 59° Norte, 19° Oeste.

Aunque existen registros de temperatura superficial del mar procedentes de diversas fuentes, se ha escogido el conjunto de datos correspondiente al barco meteorológico oceánico India por dos motivos principales. En primer lugar, se trata de un caso de estudio analizado por Hasselmann y Frankignoul, lo que permite contrastar directamente las predicciones del modelo estocástico con los resultados originales del artículo. En segundo lugar, los autores hacen esta comparación a través del análisis espectral de las anomalías de temperatura, al igual que haremos nosotros. A partir de estos datos, los investigadores predicen un tiempo característico de aproximadamente 4,5 meses para las anomalías de temperatura y las caracterizan por un espectro rojo. Cabe señalar que el barco meteorológico India formó parte de la red de estaciones oceánicas del Atlántico Norte hasta mediados de la década de 1970, aunque los datos utilizados en el estudio abarcan el periodo de 1949 a 1964. Las anomalías de temperatura son calculadas respecto a promedios temporales de 14 días.

Queremos buscar las anomalías de la temperatura superficial del mar (TSM) y demostrar que pueden ser ampliamente explicadas por la respuesta a largo plazo del océano frente al flujo constante y rápidamente cambiante de la atmósfera. Comenzamos la modelización por la descripción de cada uno de los medios:

- Para el océano consideramos un modelo simplificado basado en una capa homogénea de profundidad H en la que la temperatura es constante, T (que es la TSM). Este tipo de modelo se llama modelo de la capa de cobre. Debemos elegir adecuadamente los parámetros ρ^o y C_p^o , densidad y capacidad calorífica del océano, para comparar los datos reales con los simulados. La variable de interés con la que caracterizaremos el océano será $\tilde{T} = T - \langle T \rangle$, las anomalías de TSM. La media temporal, $\langle \cdot \rangle$ debe ser tomada como fue explicado en el desarrollo teórico, promediando sobre un tiempo τ que cumple $\tau_x \ll \tau \ll \tau_y$. En el caso del barco meteorológico India los datos corresponden a medias temporales de la temperatura cada 14 días durante 16 años. Esto nos permite (por resultados de análisis de señales) encontrar comportamientos cuasiperiódicos de tiempo característico de 1 mes o más en la TSM.
- Para la atmósfera la descripción no es tan fácil, pero es necesaria para establecer los flujos de intercambio de calor con el océano. También necesitamos conocer la influencia de las corrientes de aire sobre el océano. Debemos tener en cuenta los parámetros ρ^a , C_p^a y T^a , que son la densidad, capacidad calorífica y temperatura de la atmósfera, respectivamente. La variable que caracteriza la atmósfera es la velocidad de las corrientes de aire, $\mathbf{W}$. Esta será la variable que trataremos como ruido blanco al dar el modelo estocástico. Nuestro modelo de atmósfera será tal que:
 - I). no sea afectado por el océano (solo nos interesan las anomalías en la temperatura del océano a primer orden),
 - II). incorpore fenómenos básicos de turbulencias (queremos algo realista pero simple),
 - III). sea incompresible (en el balance de masa, $\nabla \cdot \mathbf{W} = 0$),
 - IV). sea de una capa (no hay que tener en cuenta procesos verticales),
 - V). sea periódico (para hacer análisis de Fourier),
 - VI). sea acotado (consideramos latitudes medias y, en particular, zonas delimitadas donde se puede asumir que nos encontramos en las mismas condiciones que los barcos meteorológicos que registren los datos).

Estas hipótesis parecen razonables. El modelo de Kruse utilizado en el artículo de Hasselmann y Frankignoul [11], es suficiente para cumplir nuestros requisitos. Trataremos con una atmósfera barotrópica (la densidad depende únicamente de la presión) y con un flujo de turbulencias cuasigeostrófico (aplicable en latitudes medias según la sección II.C.3 de la revisión de Ghil de 2020, [2]), a efectos prácticos tendremos una aproximación de primer orden en la variación latitudinal del parámetro de Coriolis. No hará falta acudir a las ecuaciones de Navier-Stokes del sistema para obtener las ecuaciones que rigen el funcionamiento de estos ciclos porque en estas condiciones tenemos que la atmósfera tiene un comportamiento débilmente estacionario y, además, puede ser interpretado como ruido blanco. En el artículo de Hasselmann y Frankignoul [11] se asegura que las soluciones del modelo de Kruse son débilmente estacionarias y cumplen las condiciones que hemos exigido, que son suficientes para aproximar la atmósfera como un proceso estocástico de ruido blanco frente a la variación oceánica. En las figuras 2 y 4 del mismo artículo (Hasselmann y Frankignoul, [11]) se justifica que mientras los

fenómenos asociados a la atmósfera tienen su máximo espectral en la escala de los días, los asociados al océano tienen su máximo espectral en la escala de los meses. También se justifica en el artículo que el modelo de Kruse es suficientemente fiel a la realidad, aunque se asegura que con modelos más completos se obtienen mejores aproximaciones. Como la filosofía de nuestra modelización es la de replicar el patrón sin necesidad de hacer predicciones precisas (pero sí confirmar la tendencia), esto es suficiente en nuestro caso.

El flujo de calor entre océano y atmósfera viene determinado por los flujos de calor latente y sensible J^{SH} , J^{LH} , que cumplen la relación:

$$J^{SH} + J^{LH} = C_J(1 + B)\rho^a C_p^a \cdot (T^a - T) \cdot |\mathbf{W}|, \quad (36)$$

donde C_J es el coeficiente de transferencia aerodinámica para el flujo de calor sensible y B es el cociente de flujo de calor latente sobre flujo de calor sensible. Las justificaciones de esta relación y de que los flujos de calor estimados se aproximan a los reales se encuentran en las secciones 3.(a) y 4 del artículo de Hasselmann y Frankignoul, [11], y también son necesarias para asegurar que el modelo se ajusta al caso real y que es aplicable. Si asumimos que el viento sigue un gradiente de temperatura constante y proporcional a la velocidad de norte a sur como $(T^a - T) = K \cdot (\mathbf{W} \cdot (-\hat{\mathbf{u}}_y)) =: K \cdot V$ entonces la ecuación de balance energético para el océano, desestimando los efectos de la radiación y los intercambios de calor con la termoclina, queda como:

$$\begin{aligned} H \frac{dT}{dt} &= \frac{J^{SH} + J^{LH}}{\rho^o C_p^o} \\ &= \frac{C_J(1+B)\rho^a C_p^a \cdot (T^a - T) \cdot |\mathbf{W}|}{\rho^o C_p^o} \\ &= C_J(1+B)K \cdot \frac{\rho^a C_p^a}{\rho^o C_p^o} \cdot V \cdot |\mathbf{W}| \end{aligned} \quad (37)$$

Esta es la ecuación que en un modelo de predicción numérica habitual rige la evolución del sistema climático. Recordamos que en el desarrollo teórico, en el teorema de modelización estocástica, demostramos que para aplicar el modelo estocástico debemos transformar la ecuación (37) en una ecuación equivalente en la que las variables atmosféricas $\mathbf{W}$ se parametrizan como procesos estocásticos y aparece el término de *feedback*. Para determinar esta nueva forma transformamos la ecuación (37) para trabajar con sus anomalías, $\tilde{T} = T - \langle T \rangle$:

$$\begin{aligned} H \frac{dT}{dt} - H \frac{d\langle T \rangle}{dt} &= \frac{J^{SH} + J^{LH}}{\rho^o C_p^o} - H \frac{d\langle T \rangle}{dt} \\ H \frac{d\tilde{T}}{dt} &= \frac{C_J(1+B)\rho^a C_p^a \cdot (T^a - T) \cdot |\mathbf{W}|}{\rho^o C_p^o} - H \frac{d\langle T \rangle}{dt} \\ &= C_J(1+B)K \cdot \frac{\rho^a C_p^a}{\rho^o C_p^o} \cdot V \cdot |\mathbf{W}| - H \frac{d\langle T \rangle}{dt}, \end{aligned} \quad (38)$$

donde

$$\frac{d\langle T \rangle}{dt} = \left\langle \frac{C_J(1+B)}{H} \frac{\rho^a C_p^a}{\rho^o C_p^o} \cdot (T^a - T) \cdot |\mathbf{W}| \right\rangle =: G(T). \quad (39)$$

Desarrollamos por Taylor $G(T)$ alrededor de una temperatura de equilibrio T_{eq} que obtenemos como el mediado temporal a largo plazo $\tau \geq \mathcal{O}(\tau_y)$. Por el principio de ergodicidad, esta temperatura representa la situación estable y esperable a largo plazo. Esto sería equivalente a un promediado de T en el conjunto de posibles valores de T y $\mathbf{W}$. Aplicamos Taylor a primer orden, que es el orden de interés de la aproximación:

$$G(T) = G(T_{eq}) + \left. \frac{dG}{dT} \right|_{T=T_{eq}} (T - T_{eq}) + \mathcal{O}(T^2). \quad (40)$$

Por ser T_{eq} un estado de equilibrio del sistema que cumple $G(T_{eq}) = \left. \frac{d\langle T \rangle}{dt} \right|_{T_{eq}} = 0$, si admitimos que a primer orden $T - T_{eq} \approx T - \langle T \rangle = \tilde{T}$, tendremos que:

$$G(T) \approx \left. \frac{dG}{dT} \right|_{T=T_{eq}} \cdot \tilde{T} =: -\lambda \tilde{T}. \quad (41)$$

Por lo tanto se define el término de *feedback* a primer orden de Taylor como:

$$-\left. \frac{dG}{dT} \right|_{T=\langle T \rangle} \cdot \tilde{T} = \left\langle \frac{C_J(1+B)}{H} \cdot \frac{\rho^a C_p^a}{\rho^o C_p^o} \cdot |\mathbf{W}| \right\rangle \cdot \tilde{T} = \frac{C_J(1+B)}{H} \cdot \frac{\rho^a C_p^a}{\rho^o C_p^o} \cdot \langle |\mathbf{W}| \rangle \cdot \tilde{T} = \lambda \cdot \tilde{T}. \quad (42)$$

Notamos que en este término $\langle |\mathbf{W}| \rangle$ corresponde con un estado de equilibrio de la corriente atmosférica y es, por lo tanto, constante. Esto se debe a que la escala temporal de $\mathbf{W}$ es $\tau_x \ll \tau$, el tiempo de promediado que hemos establecido previamente ($\tau = 14$ días por el tratado de los datos experimentales que contrastamos, el realizado por Hasselmann y Frankignoul en su artículo, [11]).

Escribimos:

$$\begin{aligned} \frac{d\tilde{T}}{dt} &= \frac{C_J(1+B)K}{H} \cdot \frac{\rho^a C_p^a}{\rho^o C_p^o} \cdot V|\mathbf{W}| + \frac{C_J(1+B)}{H} \cdot \frac{\rho^a C_p^a}{\rho^o C_p^o} \cdot \langle |\mathbf{W}| \rangle \cdot \tilde{T} \\ &=: K_1 \cdot V|\mathbf{W}| + \lambda \cdot \tilde{T}. \end{aligned} \quad (43)$$

En esta ecuación tenemos todo lo que necesitamos para justificar que el modelo predice que el espectro de la anomalía de TSM es rojo, concordando con la realidad. Lo único que nos queda hacer es poner la ecuación (43) en la forma de un proceso autorregresivo de primer orden como ya hicimos en el desarrollo teórico. Antes de discretizar el tiempo en la ecuación y de realizar la aproximación por diferencias finitas de la derivada, justificamos que $V \cdot |\mathbf{W}|$ corresponde a ruido blanco. Primero nos damos cuenta de que $\mathbf{W}$ y sus componentes (V es su componente en el eje $\hat{u}_y$) son normales centradas porque, al ser de escala temporal τ_x y $\tau_y \gg \tau_x$, $t \gg \tau_x$, por el teorema central del límite se comportan en esta escala como gaussianas centradas. El producto, si bien no es gaussiano, sigue siendo un ruido blanco porque $\mathbb{E}(V|\mathbf{W}|) = 0$ y $\mathbb{Var}(V|\mathbf{W}|)$ es constante. Denotamos $Z_t = V_t|\mathbf{W}_t|$ esta variable de ruido blanco. Ya podemos caracterizar $\tilde{T}$ como un proceso AR(1). Discretizamos la escala temporal, midiendo hasta un tiempo $\tau \geq \mathcal{O}(\tau_y) \gg \tau_x$, se tiene para un paso del tiempo $t \gg \tau_x$:

$$\tilde{T}_t - \tilde{T}_{t-1} = K_1 Z_t + \lambda \tilde{T}_t \quad (44)$$

y,

$$\tilde{T}_t = \frac{1}{1-\lambda} \tilde{T}_{t-1} + Z'_t, \quad (45)$$

con $Z'_t = \frac{K_1}{1-\lambda} Z_t$. Esto es un proceso AR(1) por lo que por la discusión teórica tiene un espectro rojo, como se quiere.

Confirmamos en la figura 3 que los espectros obtenidos para el barco meteorológico India y las predicciones del modelo coinciden. En efecto son la clase de espectros que llamamos rojos porque la potencia más alta se da para tiempos largos (frecuencias cortas) y para frecuencias mayores se amortigua el espectro. Hemos obtenido la figura 3.(a) como resultado de utilizar la fórmula para el espectro de un proceso AR(1), ecuación (13), con los valores de los datos sugeridos por el artículo de Hasselman y Frankignoul [11]. Estos valores son:

$$\left\{ \begin{array}{ll} C_J = 10^{-3}, & B = 3, \\ \rho^a = 1,25 \cdot 10^{-3} \text{ g/cm}^3, & C_p^a = 0,24 \frac{\text{cal}}{\text{g} \cdot \text{K}}, \\ \rho^o = 1 \text{ g/cm}^3, & C_p^o = 0,96 \frac{\text{cal}}{\text{g} \cdot \text{K}}, \\ K = 1,25 \frac{\text{K}}{\text{m/s}}, & \langle |\mathbf{W}| \rangle = 8 \text{ m/s}, \\ H = 100 \text{ m}. & \end{array} \right.$$




Fig. 3: Comparación del espectro de los datos obtenidos para las anomalías de la TSM, interpretado como un proceso AR(1), frente al espectro real. En (a) el espectro viene apropiadamente reescalado por la relación entre varianza y espectro explicada en la sección 12.3 del libro de von Storch y Zwiers, [6]. La figura (b) corresponde a los datos reales del barco India y ha sido extraída de la sección 4 del artículo de Hasselmann y Frankignoul, [11]. En esta la flecha representa la amplitud del intervalo de confianza al 95 %.

Que implican un coeficiente de *feedback*, $\lambda_{teórico} \approx (3,86 \text{ meses})^{-1}$. Este valor es consistente con lo que hubiéramos podido esperar, sin embargo, es grande comparado con $\lambda_{experimental} \approx (4,5 \text{ meses})^{-1}$ que se estima al ajustar la curva de la figura 3.(b). La inversa del coeficiente de *feedback* nos permite estimar el tiempo característico de la anomalía de TSM, por lo tanto, nuestro modelo ha estimado para el caso de esta estación meteorológica del Atlántico Norte entre 3 y 5 meses de tiempo característico. No tenemos una estimación del error para ninguno de los parámetros obtenidos, sin embargo, podemos especular sobre la discrepancia entre los factores de *feedback* estimados. Esto explicaría también que la caída de potencia entre las figuras 3.(a) y 3.(b) no sea igual de pronunciada en ambos casos, en particular para λ más pequeño (λ^{-1} más grande) la caída comprende casi tres órdenes de magnitud en el mismo rango temporal en que el factor más grande ($\lambda_{teórico}$) recorre aproximadamente dos órdenes. Que $\lambda_{teórico}$ fuera menor reduciría dicha diferencia. Recordemos las hipótesis que hemos hecho que puedan haber sido fuente de discrepancia:

→ Aproximaciones atmosféricas. Hay aquí tres partes que debemos tener en cuenta:

- La aproximación a latitudes medias. Estando a 59°N estamos estirando esta aproximación para la que la atmósfera barotrópica puede no ser realista.
- La transferencia de calor entre el océano y la atmósfera se produce con $KV = T - T^a$ para alguna constante K . En esta ecuación, además, se supone que la temperatura del aire es constante, aproximación que, si bien hemos mencionado al modelizar la atmósfera, hemos aplicado implícitamente en nuestra obtención de $\lambda = -\frac{dG}{dT}|_{T=T_{eq}}$ y en el proceso $Z'_t = \frac{K_1}{1-\lambda} \cdot V|\mathbf{W}|$ de ruido blanco. El alcance de esta aproximación es notable a efectos de cálculo y su efecto es difícil de cuantificar porque no conocemos la relación explícita $T^a(T)$ y porque afecta a la parte aleatoria del modelo.

→ Los valores tomados para el cálculo de la aproximación teórica. Respecto a los valores termodinámicos de la transferencia de calor, en el artículo de Hasselmann y Frankignoul [11] se hacen las comprobaciones apropiadas para confirmar que los flujos de calor

latente y sensible son realistas, por lo tanto asumimos que los valores de C_J y B son apropiados. También se asegura en ese trabajo que $H = 100$ m es una aproximación apropiada para las coordenadas geográficas de nuestra estación meteorológica. El valor que puede ser peor estimado, porque se estima para otras coordenadas, es el de la velocidad media del viento, $\langle |\mathbf{W}| \rangle = 8$ m/s. La cantidad de error que aporta el viento al cálculo de λ será, según nuestra definición de λ , un término $\sqrt{\dots + (\lambda \cdot \varepsilon_{rel}(\langle |\mathbf{W}| \rangle))^2}$. Si el error relativo de la estimación del viento fuera considerable el efecto podría ser notable en el cálculo del coeficiente de *feedback* λ .

Hasselmann y Frankignoul [11], apuntan a que la principal fuente de discrepancia entre el modelo y la realidad se debe a la hipótesis de que la temperatura del aire se mantiene constante. Como el objetivo era dar una modelización suficiente para demostrar que el efecto acumulado de los eventos atmosféricos tiene consecuencias en las anomalías de temperatura a largo plazo de la superficie oceánica, y hemos cumplido este objetivo, no trataremos de mejorar la estimación. Resultados más precisos se obtendrán para modelos más completos. En particular, podemos esperar que al corregir esta fuente de error obtengamos valores del tiempo característico mayores (factores de *feedback*, λ , más pequeños), porque en la realidad el aire se ajusta de forma casi inmediata a la anomalía térmica del océano. La interacción inmediata reduce la diferencia de temperatura respecto al caso en el que la temperatura de la atmósfera es constante, consecuentemente, reduce el ritmo al que el agua pierde ese exceso o defecto de calor. La relevancia principal del modelo está en la predicción de los cuasiperiodos de escala climática larga como consecuencia del efecto acumulado de los procesos de escala temporal corta, este es el “integrador” físico del que hablábamos en el desarrollo teórico y representa exactamente el comportamiento complejo del clima.

3.2. Paleoclima: resonancia estocástica y periodos glaciares.

Ya hemos comentado que Giorgio Parisi no hizo una amplia investigación en modelos de clima, sin embargo, fue una figura importante en el desarrollo del concepto de resonancia estocástica y exploró un modelo paleoclimático en el que aplicó este concepto. El modelo, explorado en el artículo de Benzi et al [16], trata de explicar la alternancia de los periodos glaciares e interglaciares terrestres. Con este ejemplo se demuestra que en ocasiones la modelización estocástica no es suficiente y se debe combinar con modelización determinista específica del contexto. El marco teórico del ejemplo se profundiza en el artículo de Suter, [17], y nos ayudaremos de él para construir el modelo. En el informe de Lucarini y Bódai, [18], se profundiza en el proceso de transición y en los estados inestables. Nosotros nos limitaremos a replicar el comportamiento básico del fenómeno considerado ilustrado en la figura 4, las glaciaciones terrestres.

En la figura 4.(a) podemos ver un espectro cualitativo que va desde los segundos hasta los millones de años y que refleja la variabilidad de las escalas climáticas terrestres durante el tiempo. Este espectro concentra en él mismo información clave sobre la historia climática de la Tierra y, en particular, sobre sus comportamientos cuasiperiódicos. Los picos que refleja esta representación que son de nuestro interés son los que ocurren en periodos de entre 10 mil y 400 mil años (en la figura, kyr=kilo-año). Como se explica en el informe de Ghil del 2002, [7], conocemos la variabilidad climática en estas escalas temporales gracias a los registros indirectos que hemos obtenido estudiando los anillos de los árboles, sedimentos marinos y corales y núcleos de hielo. En particular, los datos de la figura 4.(b) provienen del plancton fósil de sedimentos marinos del Pacífico ecuatorial e indican fluctuaciones en el volumen de hielo global a lo largo de los últimos 700 mil años. Por eso nos interesan especialmente los picos de variabilidad que están asociados a las escalas de la figura 4.(b), es decir, los de periodos




Fig. 4: Espectros de variabilidad de procesos terrestres a escalas temporales largas. En (a) vemos un espectro cualitativo realizado por un artista en el que se representan las escalas de variabilidad climática terrestre. Figura obtenida del informe de Ghil del 2002, [7]. En (b) vemos las pruebas de los periodos de glaciación terrestre, en esta figura extraída del artículo de Benzi et al [16], se muestra el espectro de las observaciones de isótopos de oxígeno en plancton fósil.

de 100 mil, 40 mil y 20 mil años de duración. El origen de los datos nos permite saber que los picos están asociados a las glaciaciones. Esta periodicidad concuerda con la de los ciclos de Milankovich, que corresponden a variaciones en las características orbitales de la Tierra causadas por su interacción gravitatoria con Júpiter y el resto de planetas. En particular e corresponde a cambios en la excentricidad de la órbita (periodo aproximado de 100 mil años), ε a cambios en la oblicuidad (periodo aproximado de 40 mil años) y π a cambios en la precesión (periodo aproximado de 20 mil años). El ciclo asociado a e , la excentricidad, es el que se relaciona con las glaciaciones terrestres.

Queremos ser capaces de predecir las glaciaciones y para ello aproximaremos la Tierra por un modelo de 0 dimensiones en el que el planeta es un punto con un flujo de energía y radiación determinado por la ecuación (4). Nos basamos en las siguientes observaciones dadas en el artículo de Sutura, [17]:

- a). La temperatura terrestre tiene dos estados estables y uno inestable.
- b). Los cambios climáticos se confinan en un rango de temperaturas de 10 K.

A estas observaciones, Sutura, en su artículo [17], añade que el sistema es antisimétrico alrededor del estado inestable (simetría impar). Esta última hipótesis sugiere que el modelo sigue una ecuación diferencial estocástica del tipo

$$\frac{dT}{dt} = -aT \cdot (T^2 - 1) + \sigma\eta_t, \quad (46)$$

donde la variable de temperatura T ha sido normalizada y η_t representa un término de ruido blanco que corresponde al efecto global de las fluctuaciones de menor escala temporal en las circulaciones atmosféricas y oceánicas sobre el comportamiento de la temperatura a largo plazo. La inclusión de este término es lo que hace que nuestra representación del sistema incorpore efectos de escala temporal menor que los de los cambios en el flujo radiativo y por eso tiene sentido acudir a la modelización estocástica a través de ruido blanco. Poner a prueba

el modelo nos ayudará a saber si las oscilaciones meteorológicas tienen efecto en el fenómeno de las glaciaciones terrestres. Linealizando la ecuación anterior nos queda la expresión

$$\frac{dT}{dt} = -2a \cdot (T - 1) + \sigma \eta_t, \quad (47)$$

que podemos aproximar por un proceso autorregresivo de orden 1. Observamos que puede parecer que hemos construido la ecuación del modelo estocástico sin atender al teorema de modelización estocástica por no haber añadido un término de *feedback*, aclaramos que este término ya estaba patente en la ecuación (47) porque estaba integrado en el balance de energía (el término $-2a(T - 1)$). Aunque la modelización parece válida, en el artículo de Benzi et al [16], se demuestra que esto es insuficiente. Si bien la ecuación (47) predice un espectro rojo para el fenómeno (que podría ser correcto), en nuestro contexto no predice ningún comportamiento periódico a largo plazo tal y como está modelizado. En su artículo, Sutera ([17]), también admite que esta modelización lineal es insuficiente para tiempos largos y para el estudio de las transiciones entre los estados de equilibrio. Aún así, utilizando la ecuación original (la ecuación (46)), Benzi et al en su artículo [16] demuestran que no se obtiene el comportamiento periódico esperado. Nos damos cuenta de que la ecuación (46) hace referencia a un doble pozo de energía potencial pues, si consideramos

$$F(T) = -aT \cdot (T^2 - 1) \implies \Phi(T) = - \int_0^T F(K) dK, \quad (48)$$

donde el potencial Φ tiene una expresión de ecuación de grado 4.

Aunque por ahora hemos visto que el efecto del ruido aleatorio climático no es suficiente para justificar los periodos glaciares a escala paleoclimática, ahora vamos a demostrar que con un balance energético adecuado que incorpore también la variabilidad de radiación solar el efecto del ruido aleatorio es necesario y suficiente para explicar el fenómeno. Volvemos al desarrollo del modelo y empezamos por desarrollar el balance energético:

$$C \frac{dT}{dt} = R_{in}(T) - R_{out}(T) = (1 - \alpha(T))Q^{SW} - Q^{LW}(T), \quad (49)$$

donde R_{in} es la radiación incidente sobre la superficie terrestre y R_{out} es la radiación saliente; α es el albedo terrestre (un valor medio apropiado del coeficiente de reflexión de la superficie terrestre); Q^{SW} es el valor medio a largo plazo de la radiación solar entrante (longitud de onda corta) y $Q^{LW}(T)$ es el valor de la radiación de longitud de onda larga emitida por la superficie terrestre. Vamos a usar las observaciones a) y b) para relacionar este balance energético con la temperatura. En primer lugar, denotamos T_1, T_2, T_3 los estados de equilibrio mencionados en la observación a). T_1 y T_3 corresponden a los estados de equilibrio estable y cumplen que $\Delta T := T_3 - T_1 = 10 \text{ K}$ y $T_1 < T_2 < T_3$. Notamos que el sistema está en equilibrio cuando la ecuación diferencial del balance energético vale 0 (estado de equilibrio), equivalentemente, cuando la función

$$f(T) = \frac{Q^{LW}(T)}{(1 - \alpha(T))Q^{SW}} = 1. \quad (50)$$

Perturbaciones $\delta(T)$ de esta función son desplazamientos del equilibrio por lo que el estado es estable si $f(T) = 1 + \delta(T) = 1$, equivalentemente, $\delta(T) = 0$. Por la hipótesis a), Benzi et al en su artículo [16] afirman que

$$\delta(T) = \beta \left(1 - \frac{T}{T_1}\right) \left(1 - \frac{T}{T_2}\right) \left(1 - \frac{T}{T_3}\right), \quad \text{con } \beta \text{ por determinar.} \quad (51)$$

Esta expresión nos lleva a la relación

$$(1 - \alpha(T))Q^{SW} = \frac{Q^{LW}(T)}{1 + \beta(1 - T/T_1)(1 - T/T_2)(1 - T/T_3)}, \quad (52)$$

que nos permite reescribir el balance energético como:

$$\frac{dT}{dt} = \frac{Q^{LW}(T)}{C} \cdot \left[\frac{1}{1 + \beta(1 - T/T_1)(1 - T/T_2)(1 - T/T_3)} - 1 \right]. \quad (53)$$

La ecuación (53), si bien es acorde a las observaciones a) y b), no atiende a ninguna de las escalas de variación de radiación del sistema. En el artículo de Benzi et al, [16], se añade como observación que en la escala de 10^4 a 10^5 años hay variaciones de temperatura que creemos que están asociadas a variaciones orbitales que influyen en la radiación solar incidente. Por este motivo se considera $Q^{SW}(t) = \mu(t)Q^{SW}$ con $\mu(t) = 1 + 0,0005 \cdot \cos(\omega t)$ y $\omega = \frac{2\pi}{10^5 \text{ años}}$. La ecuación del sistema quedaría como

$$\frac{dT}{dt} = \tilde{F}(T, t) = \frac{Q^{LW}(T)}{C} \cdot \left[\frac{\mu(t)}{1 + \beta(1 - T/T_1)(1 - T/T_2)(1 - T/T_3)} - 1 \right]. \quad (54)$$

En el artículo De Benzi, Parisi, Sutera y Vulpiani, [16], se justifica que esta formulación tampoco es suficiente y que predice variaciones de temperatura de únicamente 1 K. La solución pasa por añadirle el término estocástico correspondiente a las variaciones de menor escala temporal en las circulaciones atmosféricas y oceánicas, η_t , término que habíamos considerado previamente en la ecuación (46). La ecuación final queda como:

$$\frac{dT}{dt} = \tilde{F}(T, t) + \eta_t = \frac{Q^{LW}(T)}{C} \cdot \left[\frac{\mu(t)}{1 + \beta(1 - T/T_1)(1 - T/T_2)(1 - T/T_3)} - 1 \right] + \eta_t. \quad (55)$$

Como en el caso de la ecuación (46) no ha sido necesario añadir un término de *feedback* porque toda la variabilidad ya está incluida en la función $\tilde{F}(T, t)$. El tiempo característico teórico del fenómeno lo calculamos como $\tau = \left(\frac{\partial \tilde{F}}{\partial T} \Big|_{T=T_1} \right)^{-1}$. Usando esta derivada también podríamos determinar el valor de β si utilizamos el valor experimental de τ para ello. El modelo ahora predice correctamente la variabilidad térmica y la escala temporal del proceso (la confirmación se justifica en el artículo de Benzi et al, [16], mientras que las herramientas matemáticas para calcular las probabilidades de transición de un estado de equilibrio a otro y dar tiempos característicos teóricos se encuentran en el artículo de Sutera, [17]). En la figura 5 se comprueba que la ecuación (55) replica la variabilidad térmica. Se observa en la figura 5.(a) que se pasa de un estado de equilibrio estable a temperatura T_1 (o desde T_3) a uno de temperatura T_3 (o hasta T_1) cada 40 mil años, aproximadamente. Este hecho se confirma en la figura 5.(b), donde se observa el pico de potencia espectral alrededor de $\omega = 75 \cdot 10^{-6} \text{ años}^{-1}$, que corresponde a un cuasiperiodo de $T = 83,8 \cdot 10^3 \text{ años}$. Este modelo, al igual que el de la ecuación (46), también representa un modelo de doble pozo (se puede ver representando $\tilde{\Phi}(T) = - \int_0^T \tilde{F}(K) dK$).

Recapitulando, hemos necesitado utilizar simultáneamente el comportamiento periódico de la radiación solar y el ruido estocástico de corto plazo para explicar el desplazamiento del sistema climático terrestre de un punto de equilibrio estable (a una temperatura T_1) a otro equilibrio estable (de temperatura T_3) en el largo plazo. Ninguna de las modelizaciones que ignoraba un efecto o el otro conseguía modelizar correctamente el fenómeno y, por lo tanto, concluimos que el modelo demuestra que ambas componentes son necesarias para explicar los cambios en el equilibrio térmico. Esta clase de sistemas en los que tenemos un fenómeno




Fig. 5: Simulación numérica del modelo regido por la ecuación (55), para el que se ha elegido una varianza de las fluctuaciones térmicas estocásticas de $0,15 \text{ K}^2/\text{año}$. Figuras obtenidas de la sección 4 del artículo de Benzi, Parisi, Sutura y Vulpiani, [16]. En (a) se muestra la temperatura media simulada para la que se observan cuasiperiodos de alrededor de 80 mil años. En (b) se muestra el espectro de la simulación numérica, donde la frecuencia corresponde a ciclos por año.

periódico débil (como es la variación de la radiación solar incidente) y un proceso de ruido blanco (en este caso las oscilaciones de temperatura en la Tierra debidas a las corrientes atmosféricas y oceánicas), producen el fenómeno conocido como resonancia estocástica, que actúa como un forzamiento necesario para realizar ese cambio entre estados de equilibrio que observábamos. La resonancia estocástica es un fenómeno útil para la modelización de ciertos eventos no lineales en sistemas complejos.

3.3. Estanques de hielo derretido en el Ártico.

La última aplicación que consideraremos se modelará en términos de la teoría desarrollada por Parisi. El objetivo es la predicción de la formación de estanques de hielo derretido en bloques de hielo del océano Ártico. Conocer la proporción y distribución de estanques de hielo es importante para poder estimar correctamente el valor del albedo terrestre. Este modelo será nuestra demostración de la aplicabilidad de las técnicas teóricas para el estudio de sistemas complejos de Parisi. Nos basamos en el artículo de Ma et al, [19], que si bien no utiliza la metodología de las réplicas propuesta por Parisi, veremos que utiliza una formulación y resolución equivalente.

Consideramos una superficie del océano Ártico congelada con hielo “nuevo” (una capa de hielo de aproximadamente un año de antigüedad), para poder limitarnos a un modelo bidimensional. Realizamos un mallado de la superficie (de $n \times n$ puntos o nodos) y decimos que cada nodo $j \in \{1, \dots, n^2\}$ puede estar en un estado de espín positivo, $s_j = +1$, que corresponde a un nodo con agua derretida; o bien en un estado de espín negativo, $s_j = -1$, un nodo de agua congelada. Para poder hacer predicciones sobre la geometría de los estanques sobre el hielo debemos tener en cuenta la topografía de la superficie que hemos elegido, por ello, debemos actualizar la ecuación (34) para incluir las variables aleatorias h_j , que representan la altura del nodo j . Al igual que en el caso magnético, si bien la distribución de los espines es aleatoria, existe una regla que determina la evolución de un nodo. Si un nodo está rodeado por una mayoría de nodos de un signo de espín concreto (por ejemplo, si son nodos positivos el nodo central está rodeado de agua), el nodo adquiere este espín por difusión de calor. Si por el contrario hay un empate, es el signo de h_j el que decide el signo del espín del nodo. Teniendo en cuenta que los coeficientes de interacción J_{jk} serán constantes, nos queda el hamiltoniano

para el sistema:

$$\mathcal{H} = \sum_j h_j s_j - \sum_{\langle j,k \rangle} J_{jk} s_j s_k. \quad (56)$$

En el estudio de Ma et al, [19], a diferencia de en el caso del modelo original de Parisi, los autores buscan estados metaestables del sistema minimizando el hamiltoniano a través de la dinámica de Glauber, un algoritmo heurístico que minimiza $\mathcal{H}$ actualizando uno a uno cada estado de espín siempre que lleve a una configuración de menor energía. Al terminar este proceso se obtiene un estado metaestable del sistema. En el artículo de Ma et al, [19], se replican los datos reales en predicciones para superficies de entre 10 m² y 1000 m². Esto se comprueba replicando la distribución de probabilidad de la superficie de los estanques en el área (que es una ley potencial de parámetro $\lambda = -3/2$) y a través de la dimensión fractal del sistema.

Si bien esta modelización cambia un poco respecto a la original de Parisi, sus resultados todavía se sostienen. Por una parte, el artículo de Ma et al, [19], demuestra que en el límite termodinámico también tenemos infinitos estados termodinámicos puros. Respecto a las réplicas del sistema y su simetría, el hecho de encontrar los diferentes estados metaestables es equivalente a la idea de la ruptura de simetría para pequeñas perturbaciones que revela la existencia de los estados emergentes en el modelo original. La ruptura de simetría de este sistema significa, por lo tanto, encontrar un mínimo local del mismo; encontrar un estado metaestable (una disposición geométrica particular) de estanques sobre el hielo.

4. Conclusiones.

El objetivo principal de este trabajo ha sido establecer los principios físicos y matemáticos relacionados con el sistema climático terrestre como sistema complejo analizando las contribuciones de Hasselmann y de Parisi a este campo de estudio. A lo largo del desarrollo teórico hemos establecido las herramientas y conceptos matemáticos y físicos mínimos para explicar las contribuciones de Hasselmann y de Parisi a la modelización climática. Conviene resaltar que estas aportaciones son desiguales. Así, mientras que Hasselmann desarrolla herramientas específicas para sistemas climáticos, Parisi aporta conceptos generales de sistemas complejos que luego encuentran aplicaciones climáticas.

A continuación, discutimos las principales conclusiones obtenidas en este trabajo:

- I). **Klaus Hasselmann:** En el desarrollo teórico hemos visto los requisitos mínimos para aplicar la modelización estocástica que desarrolló, y hemos concluido que los resultados que podemos esperar de ella son orientativos pero suficientes para obtener un mejor entendimiento de la realidad física. En la parte de aplicaciones hemos conseguido evidencia suficiente utilizando su modelo estocástico para anomalías en la temperatura superficial del mar consistente con la idea de que los eventos meteorológicos de la atmósfera tienen efectos a largo plazo en la temperatura oceánica. La aparición de este fenómeno que integra las fluctuaciones rápidas en una escala temporal larga es claramente una característica de los sistemas complejos, tal y como establecimos en la introducción. Hemos conseguido utilizar el marco teórico de Hasselmann para describir fenómenos complejos en sistemas climáticos.
- II). **Giorgio Parisi:** El marco teórico de Parisi ha sido más reducido porque su trabajo en sistemas climáticos se reduce al desarrollo del modelo paleoclimático de eras glaciares terrestres del artículo de Benzi, Parisi, Sutera y Vulpiani [16]. Hemos introducido el funcionamiento básico de los *spin glasses* y resumido las principales aportaciones de Parisi

en este campo. En la parte de aplicaciones hemos utilizado un método equivalente al desarrollado por Parisi para *spin glasses* con el que hemos presentado un modelo que predice la configuración de estanques en terrenos helados del Ártico, un sistema climático que es complejo porque de la interacción entre los nodos emergen infinitos estados metaestables. Su trabajo sobre la resonancia estocástica (el modelo paleoclimático), es el que nos da el nexo real entre Parisi y la física del clima. Este modelo es especialmente sugestivo porque demuestra que la combinación de efectos deterministas (el forzamiento periódico) y estocásticos es la causa de un fenómeno complejo. En el desarrollo de esta aplicación demostramos que ni el forzamiento periódico ni el forzamiento estocástico son suficientes por sí solos para explicar los estados de equilibrio glaciares e interglaciares que experimenta la Tierra.

- III). Las aportaciones de Hasselmann y de Parisi abordan los sistemas complejos desde perspectivas distintas, pero las contribuciones de los dos nos dan descripciones adecuadas y complementarias de los sistemas complejos. Mientras que Hasselmann explica cómo el ruido meteorológico genera variabilidad climática de largo plazo, Parisi proporciona herramientas para entender comportamientos y estados emergentes. Ambas características definen los sistemas complejos y se reflejan en los modelos climáticos

En resumen, hemos indagado en el funcionamiento de los sistemas climáticos, hemos demostrado que podemos utilizar modelos estocásticos propuestos por Hasselmann para representar dichos sistemas y hemos utilizado estos modelos para demostrar el origen de los fenómenos complejos en dos de nuestros ejemplos. Por otra parte hemos presentado el marco teórico de la investigación de Parisi en sistemas complejos y un ejemplo de su aplicación en un sistema climático.

4. Conclusions

The main objective of this work has been to establish the physical and mathematical principles underlying the Earth's climate system as a complex system by analysing the contributions of Hasselmann and Parisi to this field of research. Throughout the theoretical development, we have introduced the minimum mathematical and physical concepts required to explain the contributions of Hasselmann and Parisi to climate modelling. It is important to note that these contributions are not equivalent in scope: Hasselmann developed tools specifically designed for climate systems, whereas Parisi provided general concepts from complex systems theory that later found applications in climate science.

We now analyse the main conclusions from our work:

- I). **Klaus Hasselmann:** In the theoretical section, we examined the minimum requirements for applying the stochastic modelling framework developed by Hasselmann and concluded that the results obtained from it are approximate yet sufficiently accurate to improve our understanding of physical reality. In the applications section, we obtained evidence from his stochastic model of sea surface temperature anomalies that is consistent with the idea that short-term atmospheric weather events can have long-term effects on ocean temperature. The emergence of this phenomenon, whereby rapid fluctuations are integrated into a much longer temporal scale, is a characteristic feature of complex systems, as established in the introduction. Therefore, we have successfully used Hasselmann's theoretical framework to describe complex phenomena within climate systems.

- II). **Giorgio Parisi:** The theoretical framework devoted to Parisi has been more limited because his direct contribution to climate science is largely restricted to the paleoclimatic model of glacial cycles proposed in the article by Benzi, Parisi, Sutera, and Vulpiani [16]. We introduced the basic principles of spin glasses and summarised Parisi's main contributions in this field. In the applications section, we employed a method equivalent to that developed by Parisi for spin glasses to present a model capable of predicting the configuration of melt ponds in Arctic ice-covered regions, a climate-related system whose complexity arises from the emergence of a large number of metastable states through the interactions between its nodes. His work on stochastic resonance, represented by the paleoclimatic model, provides the most direct link between Parisi and climate physics. This model is particularly compelling because it demonstrates that the combination of deterministic effects (the periodic forcing) and stochastic effects is responsible for the emergence of a complex phenomenon. In the development of this application, we showed that neither the periodic forcing nor the stochastic forcing alone is sufficient to explain the glacial and interglacial equilibrium states experienced by the Earth.
- III). The contributions of Hasselmann and Parisi approach complex systems from different perspectives, yet together they provide complementary and consistent descriptions of such systems. Whereas Hasselmann explains how meteorological noise generates long-term climate variability, Parisi provides tools for understanding emergent behaviours and states. Both features are defining characteristics of complex systems and are reflected in climate models.

In summary, we have explored the functioning of climate systems, demonstrated that the stochastic models proposed by Hasselmann can be used to represent them, and employed these models to explain the origin of complex phenomena in two of our examples. Furthermore, we have presented the theoretical framework of Parisi's research on complex systems and an example of its application to a climate-related system.

Bibliografía

- [1] ROSE Joanna. *They found hidden patterns in the climate and in other complex phenomena*, The Royal Swedish Academy of Sciences, 2021, *Popular Science Background*, url: <https://www.nobelprize.org/prizes/physics/2021/popular-information/>.
- [2] GHIL, Michael y LUCARINI, Valerio. *The physics of climate variability and climate change*, American Physical Society, *Reviews of Modern Physics*, vol. 92, págs. 35002-35079, 2020.
- [3] THE NOBEL COMMITTEE FOR PHYSICS. *For groundbreaking contributions to our understanding of complex physical systems*, The Royal Swedish Academy of Sciences, 2021, *Scientific Background*, url: <https://www.nobelprize.org/prizes/physics/2021/advanced-information/>.
- [4] FRANZKE, Christian L.E. BLENDER, Richard, O'KANE, Terence J. y LEMBO, Valerio, *Stochastic Methods and Complexity Science in Climate Research and Modeling*, *Frontiers Physics*, 10:931596, 2022.

- [5] BOHÉMIER, Kayleigh Ayn. *Analysis for Science Librarians of the 2021 Nobel Prize in Physics: Climate, Spin Glass, and Complex Systems.*, Sci Technol Libraries, vol. 41:1, págs. 1-23, 2022.
- [6] VON STORCH, Hans y ZWIERS, Francis W. *Statistical Analysis in Climate Research.*, Cambridge University Press, 2003.
- [7] GHIL, Michael. *Natural Climate Variability*, John Wiley & Sons, *Encyclopedia of Global Environmental Change*, vol. 1, págs. 544-549, 2002.
- [8] HASSELMANN, Klaus. *On the signal-to-noise problem in atmospheric response studies*, Royal Meteorology Society, *Meteorology of Tropical Oceans*, págs. 251-259, 1979.
- [9] HASSELMANN, Klaus. *Optimal Fingerprints for the Detection of Time-dependent Climate Change*, American Meteorological Society, *Journal of Climate*, vol. 6, págs. 1957-1971, 1993.
- [10] HASSELMAN, Klaus. *Stochastic climate models. Part I: Theory*, Tellus, vol.28, págs 473-485, 1976.
- [11] FRANKIGNOUL, Claude y HASSELMANN, Klaus. *Stochastic climate models. Part II: Application to sea-surface temperature anomalies and thermocline variability*, Tellus, vol.29, págs 289-305, 1977.
- [12] LEMKE, Peter. *Stochastic climate models. Part 3: Application to zonally averaged energy models*, Tellus, vol.29, págs 385-392, 1977.
- [13] LABBÉ, Cyril. *Calcul stochastique et modèles de diffusion*, M2MO: Modélisation Aléatoire, Finance et Data Science, Université Paris Cité, 2025, url: <https://www.dropbox.com/scl/fi/w47eopuzwo5pu0lke5uki/Cyril-Labb.pdf?rlkey=3796eszbn7paih6v82t39pzd&st=04mv30t2&dl=0>.
- [14] NISHIMORI, Hidetoshi. *Statistical Physics of Spin Glasses and Information Processing An Introduction*, Oxford University Pressk 2001.
- [15] PARISI, Giorgio. *Order parameter for spin-glasses*, American Physical Society, *Physical Review Letters*, vol. 50, págs. 1946-1948, 1983.
- [16] BENZI, Roberto, PARISI, Giorgio, SUTERA, Alfonso y VULPIANI, Angelo. *Stochastic resonance in climatic change*, Tellus, vol.34, págs 10-16 1982.
- [17] SUTERA, Alfonso. *On stochastic perturbation and long-term climate behaviour*, John Wiley & Sons, *Quarterly Journal of the Royal Meteorological Society*, vol. 107, págs. 137-151, 1981.
- [18] LUCARINI, Valerio y BÓDAI, Tamás. *Transitions across Melancholia States in a Climate Model: Reconciling the Deterministic and Stochastic Points of View*, American Physical Society, *Physical Review Letters*, vol. 122, 158701, 2019.
- [19] MA, Yi-Ping, SUDAKOV, Ivan, STRONG, Courtenay y GOLDEN, Kenneth M. *Ising model for melt ponds on Arctic sea ice*, IOP Publishing Ltd, *New J. Phys*, 21:063029, 2019.